

Содержание

1	Наводящие размышления	2
2	Повторные выборки (Ресемплинг)	3
2.1	Введение	3
2.2	Джекнайф	6
2.2.1	Немного о самом методе	6
2.2.2	Джекнайф-оценка смещения	10
2.2.3	Джекнайф-оценка дисперсии	15
2.3	Бутстрэп	16
2.3.1	Общая идея оценок методом бутстрэп	16
2.3.2	Метод бутстрэп	17
2.3.3	Построение доверительных интервалов	20
2.3.4	Некоторые финальные замечания	21
3	Ансамбли моделей	21
3.1	Общее понятие ансамбля	21
3.2	Бэггинг	26
3.2.1	Пример решения задачи классификации	26
3.2.2	Пример задачи регрессии	29
3.3	Адаптивный бустинг для двухклассовой классификации (AdaBoost)	33
3.3.1	Пример	36
3.4	Стекинг (Stacking)	41
3.4.1	Пример на пальцах	42
3.5	Случайный лес	44
4	Многоклассовая классификация	46
4.1	Один против всех (one-vs-all)	47
4.1.1	Пример	48
4.2	Все против всех (all-vs-all)	51
4.2.1	Пример	53



2.3 Бутстрэп

Давайте рассмотрим еще один из методов генерации повторных псевдо-выборок – бутстрэп. Этот метод был предложен в 1979 году Брэдли Эфроном (Bradley Efron), и с тех пор заработал заслуженную популярность. Он, как и джекнайф, позволяет оценивать различные характеристики рассматриваемой статистики такие, как смещение и дисперсию, позволяет строить доверительные интервалы и так далее. В то же время, границы применимости этого метода намного шире, чем метода джекнайф, естественно, за счет большей вычислительной сложности.

2.3.1 Общая идея оценок методом бутстрэп

Итак, попробуем самостоятельно, из логических соображений прийти к методу бутстрэп. Пусть, как обычно, θ – некоторый неизвестный параметр (или характеристика) распределения генеральной совокупности ξ , $X_1, X_2, \dots, X_n$ – выборка из генеральной совокупности ξ , а

$$\hat{\theta} = \hat{\theta}_n(X_1, X_2, \dots, X_n)$$

– некоторая (состоятельная) оценка θ . На конкретной выборке (в результате эксперимента) мы можем получить лишь конкретное (одно) значение нашей оценки $\hat{\theta}$, а значит никак не можем оценить ни среднее, ни разброс, ни, тем более, построить какой-либо доверительный интервал для θ . Как же поступать в таком случае?

Сначала представим себе «идеальную ситуацию». Пусть мы можем получить не одну выборку из генеральной совокупности, а, скажем, B штук. Тогда у нас в руках B наборов

$$X_1^{(j)}, X_2^{(j)}, \dots, X_n^{(j)}, \quad j \in \{1, 2, \dots, B\}$$

независимых и одинаково (с ξ) распределенных случайных величин, на каждом из которых мы можем вычислить значение нашей статистики $\hat{\theta}$

$$\hat{\theta}^j = \hat{\theta}_n^{(j)}(X_1^{(j)}, X_2^{(j)}, \dots, X_n^{(j)}), \quad j \in \{1, 2, \dots, B\}.$$

Совершенно ясно, что разумной оценкой как математического ожидания, так и дисперсии $\hat{\theta}$ являются

$$\hat{\theta}_{(\bullet),B} = \frac{1}{B} \sum_{j=1}^B \hat{\theta}^j$$

и

$$\widehat{\text{Var}}_B = \frac{1}{B-1} \sum_{j=1}^B \left(\hat{\theta}^j - \frac{1}{B} \sum_{j=1}^B \hat{\theta}^j \right)^2 = \frac{1}{B-1} \sum_{j=1}^B \left(\hat{\theta}^j - \hat{\theta}_{(\bullet),B} \right)^2.$$

Все сказанное ранее подтверждается и теоретически – изложенное, по сути своей, – это хорошо известный в статистике метод Монте-Карло. Все бы было хорошо, но перед нами маячит вот такая проблема: обычно мы не можем получать сколько угодно выборок из генеральной совокупности. Что же в таком случае делать? Как применить, вроде бы, совершенно логичные рассуждения, которые мы привели? Тут и возникает бутстрэп.

2.3.2 Метод бутстрэп

Метод бутстрэп основывается вот на какой идее. Пусть $X_1, X_2, \dots, X_n$ – выборка. Опираясь на нее, мы можем смоделировать распределение ξ и в последствии получить необходимые выборки из смоделированного распределения. Такой подход позволит нам применить аппарат, описанный ранее.

Как известно из статистики, истинное распределение ξ по выборке $X_1, X_2, \dots, X_n$ разумно приближается эмпирическим с функцией распределения

$$F_n^*(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{I}(X_i < x),$$

где $I(A)$ – индикатор события A , аналитическое задание которого следующее:

$$I(A) = \begin{cases} 1, & A \text{ произошло} \\ 0, & A \text{ не произошло} \end{cases}.$$

Имея же функцию распределения, мы легко можем моделировать выборки нужного нам объема. Но чему, по сути дела, это эквивалентно? Конечно, формированию выборок путем случайного выбора n объектов с возвращением из исходной выборки.

Определение 2.3.1 Бутстрэп-выборками объема n из выборки $X_1, X_2, \dots, X_n$ называются наборы

$$X_1^{(j)}, X_2^{(j)}, \dots, X_n^{(j)},$$

где $X_i^{(j)} \in \{X_1, X_2, \dots, X_n\}$.

Понятно, что число таким образом полученных выборок чрезвычайно велико! Индекс j может принимать значения из диапазона $\{1, 2, \dots, n^n\}$ и, например, для выборки объема 12 количество бутстрэп-выборок равно

$$12^{12} = 8\,916\,100\,448\,256$$

– числу, даже названия разрядов которого знает далеко не каждый. Поэтому на практике, конечно, берут куда меньшее бутстрэп-выборок, чем существует на самом деле.

Замечание 2.3.1 Так как выбор производится с возвращением, то в бутстрэп-выборках могут встречаться повторяющиеся элементы исходной выборки. Интересно, что с ростом n доля уникальных элементов исходной выборки, встречающихся в бутстрэп-выборке, стремится к ≈ 0.632 .

Пусть мы «набираем» выборку $S_1, S_2, \dots, S_n$. Для каждого элемента исходной выборки $X_1, X_2, \dots, X_n$ вероятность, что $S_i \neq X_j$ равна

$$P(S_i \neq X_j) = 1 - \frac{1}{n}.$$

Так как выбор производится независимо, то

$$P(S_1 \neq X_j, S_2 \neq X_j, \dots, S_n \neq X_j) = \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow +\infty} e^{-1} \approx 0.368.$$

Значит, вероятность того, что элемент X_j встретится в набираемой нами выборке равна

$$1 - e^{-1} \approx 0.632,$$

и это справедливо для любого элемента исходной выборки, то есть при всех $j \in \{1, 2, \dots, n\}$.

Итак, после генерации бутстрэп-выборок, алгоритм получения оценок математического ожидания и дисперсии оценки $\hat{\theta}$ следующий.

1. Пусть сгенерировано B бутстрэп-выборок

$$X_1^{(j)}, X_2^{(j)}, \dots, X_n^{(j)}, \quad j \in \{1, 2, \dots, B\}.$$

2. На каждой из них вычисляется значение $\hat{\theta}$,

$$\hat{\theta}^j = \hat{\theta}_n^j(X_1^{(j)}, X_2^{(j)}, \dots, X_n^{(j)}), \quad j \in \{1, 2, \dots, B\}.$$

3. В качестве оценок математического ожидания и дисперсии $\hat{\theta}$ берутся

$$\hat{\theta}_{(\bullet),B} = \frac{1}{B} \sum_{j=1}^B \hat{\theta}^j$$

и

$$\widehat{\text{Var}}_B = \frac{1}{B-1} \sum_{j=1}^B \left(\hat{\theta}^j - \frac{1}{B} \sum_{j=1}^B \hat{\theta}^j \right)^2 = \frac{1}{B-1} \sum_{j=1}^B \left(\hat{\theta}^j - \hat{\theta}_{(\bullet),B} \right)^2,$$

соответственно.

Определение 2.3.2 Введенные выше величины

$$\hat{\theta}_{(\bullet),B} = \frac{1}{B} \sum_{j=1}^B \hat{\theta}^j$$

и

$$\widehat{\text{Var}}_B = \frac{1}{B-1} \sum_{j=1}^B \left(\hat{\theta}^j - \frac{1}{B} \sum_{j=1}^B \hat{\theta}^j \right)^2 = \frac{1}{B-1} \sum_{j=1}^B \left(\hat{\theta}^j - \hat{\theta}_{(\bullet),B} \right)^2,$$

называют бутстрэп-оценками математического ожидания и дисперсии оценки $\hat{\theta}$, соответственно.

Пример 2.3.1 Рассмотрим уже знакомый пример, когда генеральная совокупность имеет распределение $U_{\theta, \theta+1}$ с параметром $\theta = 2.5$. Выполним моделирование и найдем истинные значения дисперсии оценки, а также джекнайф и бутстрэп-оценки дисперсии $\hat{\theta} = X_{(1)}$. Можно заметить, что при малых значениях n результаты варьируются, однако зачастую джекнайф-оценка дисперсии меньше. И наоборот, начиная с некоторого n , бутстрэп-оценка дисперсии меньше или совпадает с джекнайф-оценкой дисперсии. Практика показывает, что метод джекнайф лучше показывает себя на малых выборках, а бутстрэп предпочтителен для больших объемов данных.



Рис. 3: Зависимость оценок дисперсии $\widehat{\text{Var}}_{jack}$ и $\widehat{\text{Var}}_B$ от объема выборки n

2.3.3 Построение доверительных интервалов

Построение доверительных интервалов для θ опирается на ровно те же самые идеи, что озвучены ранее. Рассмотрим здесь лишь самый простой случай. Если допустить, что

$$\frac{\widehat{\theta} - \theta}{\sqrt{D_{\theta}\widehat{\theta}}} \xrightarrow[n \rightarrow +\infty]{d} \eta \sim N_{0,1},$$

или близко к нормальному, а $\widehat{\text{Var}}_B$ – состоятельная оценка $D_\theta \hat{\theta}$, то асимптотический доверительный интервал уровня $(1 - \varepsilon)$ для параметра θ строится обычным образом и имеет вид

$$\left(\hat{\theta} - \tau_{1-\varepsilon/2} \sqrt{\widehat{\text{Var}}_B}, \hat{\theta} + \tau_{1-\varepsilon/2} \sqrt{\widehat{\text{Var}}_B} \right),$$

где $\tau_{1-\varepsilon/2}$ – квантиль уровня $(1 - \varepsilon/2)$ стандартного нормального распределения.

2.3.4 Некоторые финальные замечания

Рассмотрению методов ресемплинга можно посвятить не одну лекцию. Рассмотренные нами моменты и подходы – это лишь часть тех бонусов, что дает исследователю бутстрэп. Аналогично тому, как было сделано в методе джекнайф, бутстрэп может оценивать и улучшать смещение исходной оценки $\hat{\theta}$ и многое другое.

Кроме того, все, что обсуждалось ранее, относится к непараметрическому бутстрэпу – мы не выдвигаем никаких предположений о распределении ξ . В то же время, если известно, каким образом распределение ξ зависит от интересующего нас параметра, метод может быть существенно усилен. Бутстрэп выборки в этом случае генерируются из эмпирической функции распределения, в которую вместо неизвестного параметра θ может быть подставлена его оценка. В этом случае количество бутстрэп выборок может быть сколь угодно большим.

Итак, теперь мы готовы посмотреть, как изученные методы применяются на практике к построению ансамблей моделей.