

Содержание

1	Понятие обучения с подкреплением	2
1.1	Базовые определения и постановка задачи	2
1.2	Компромисс изучение-применение	5
1.3	Постановка задачи о k -руком бандите	6
1.4	Жадная стратегия	10
1.5	ε -жадная стратегия	13
1.6	Softmax-стратегия	17
1.7	Метод UCB (Upper Confidence Bound)	19
1.8	Оптимистичные начальные оценки	22
2	Общая постановка задачи	24
2.1	Взаимосвязь агента и окружающей среды	24
2.2	Функции ценности действий и состояний	32
2.3	Пример	35
2.4	Оценка стратегий	39
2.5	Оптимальные стратегии	46
2.6	SARSA	55
2.7	Q-обучение	60
2.8	Пример	63
2.9	Резюме	65
3	Заключение	65

1 Понятие обучения с подкреплением

1.1 Базовые определения и постановка задачи

Здравствуйте, уважаемые слушатели! В этой лекции мы обсудим еще одну ветку, или еще один тип машинного обучения – обучение с подкреплением. Но начнем, конечно же, с мотивировки и отличий от тех типов, что уже были изучены ранее.

Итак, давайте вспомним с чем мы имеем дело, решая, скажем, задачу обучения с учителем? У нас есть набор предикторов (или входных переменных) $X_1, X_2, \dots, X_p$ и набор откликов Y (или набор правильных ответов). Нашей задачей является обобщение «имеющегося опыта» (опыта, основанного на тренировочных данных) на «все пространство» (на произвольные тестовые данные). Например, решая задачу регрессии при $p = 1$, мы имеем в руках лишь (грубо говоря) набор из n пар данных $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$. Наша же цель – построить зависимость вида $Y = f(X)$, которая способна предсказать «правильный ответ» уже для любого X из возможного множества значений предиктора X_1 .

Аналогично и с задачей классификации: просто вспомните, как, зная классы лишь конечного числа тренировочных объектов, в результате классификации все пространство признаков (с бесконечным числом объектов) «раскрашивается» в разные цвета, отвечающие тому или иному классу. Вот оно – обобщение на все пространство. Понятно, что аналогичные рассуждения справедливы и при рассмотрении обучения без учителя.

Однако в реальной жизни обучение происходит далеко не всегда по схеме, в которой известны «верные ответы». Скажем, разработка учеными нового лекарственного препарата, или вывод математиками очередной хитрой формулы, – это процессы, не имеющие откликов, кроме финального: работает препарат или нет, получилась формула или нет. Сам же процесс создания (будь то формулы или препарата), скорее всего, описывается примерно так: мы что-то делаем, в результате наших действий что-то происходит, этот результат мы как-то оцениваем, обдумываем, а затем продолжаем что-то делать, стараясь приблизиться к желаемому результату. Согласитесь, под такую вольно описанную логику подходит куча различных процессов, встречающихся в повседневной жизни на каждом шагу:

1. Например, а как ребенок учится вставать, научившись ползать (описание процесса может быть не очень точным)? Сначала он предпринимает множество попыток встать с колен, но, по понятным причинам, постоянно падает. Однако через какое-то время он понимает (конечно, из опыта), что когда его поддерживает рука мамы, то встать гораздо проще. Значит, нужно за что-то держаться, вставая. Стол, стул, да хотя бы

стена – все подойдет. Остается только немного покарабкаться, и вуаля – человек научился вставать.

2. А как проходит футбольный матч? Конечно, у каждой команды есть заранее продуманная тактика, учитывающая как сильные, так и слабые стороны как соперников, так и себя (кстати, наработанный опытом). Но ход игры слишком непредсказуем: почему-то именно сегодня нападающий достаточно легко может попасть к воротам соперника именно со стороны правого фланга. Видимо, защитники думают о чем-то другом. Что же, это «на руку», значит по этому флангу и имеет смысл в основном атаковать.

Конечно, можно привести еще множество различных примеров, но, скорее всего, идея ясна. Давайте теперь подойдем к некоторой формальной постановке задачи и введем определения, которые будем повсеместно использовать в дальнейшем.

Итак, говоря несколько грубо, обучение с подкреплением – это раздел машинного обучения, основывающийся на следующей парадигме: обучаемая модель не имеет детальных сведений об окружающей ее системе, однако может производить в ней (в этой системе) какие-то действия, анализируя реакцию системы на эти действия. Иными словами, анализируя подкрепления. Ясно, что как модель воздействует на систему, так и система воздействует на модель, поэтому пару система-модель разлучать нельзя. Так что следующее определение носит весьма условный характер.

Определение 1.1.1 *Модель, обучающуюся в рамках задачи обучения с подкреплением, часто называют агентом. Окружающую агента систему часто называют средой.*

Перейдем к формальному описанию процесса взаимодействия агента и среды.

1. Пусть агент и среда взаимодействуют в дискретные моменты времени $t \in \{0, 1, 2, \dots, n\}$, $n \in \mathbb{N} \cup \{0, \infty\}$: количество взаимодействий может быть как конечным (если n конечно), так и бесконечным.
2. На каждом шаге агент находится в каком-то состоянии $s_t \in S$, где S – множество всех возможных состояний.
3. На основании состояния s_t , агент выбирает некоторое действие $a_t \in A(s_t)$, где $A(s_t)$ – множество действий, доступных агенту в состоянии s_t .
4. Совершив действие a_t , среда генерирует награду r_{t+1} и переводит агента в состояние s_{t+1} .

5. Шаги 3-4 повторяются, если не достигнут какой-то критерий останова.

В дальнейшем мы подробно поясним, что означают слова «генерирует», «переводит», и опишем всю схему математически корректно. Сейчас же, чтобы закрепить общее понимание происходящего, приведем весьма условный пример диалога между средой и агентом:

1. **Среда:** Агент, ты в состоянии s_0 . Тебе доступны действия с номерами 3, 4, 5 ($A(s_0) = \{3, 4, 5\}$).

Агент: Совершаю действие с номером 4 ($a_0 = 4$).

2. **Среда:** Ты получаешь награду в 3 единицы ($r_1 = 3$) и переходишь в состояние s_1 . Теперь тебе доступны действия с номерами 1, 4, 5 ($A(s_1) = \{1, 4, 5\}$).

Агент: Совершаю действие с номером 5 ($a_1 = 5$).

3. **Среда:** Ты получаешь награду в -1 единицу ($r_2 = -1$) и переходишь в состояние s_2 . Тебе доступны ... Ну и так далее.

Как мы видим, награды (или подкрепления) могут быть как положительными, так и отрицательными. Задача агента – максимизировать накопительную награду, опирается на следующую гипотезу (так называемую гипотезу о вознаграждении – Reward Hypothesis): «Все цели могут быть описаны путем максимизации ожидаемого совокупного вознаграждения» («All goals can be described by the maximisation of expected cumulative reward»). О том, что понимается под этими словами, мы поговорим чуть позже.

Итак, надеемся, что схема взаимодействия прозрачна и ясна. Однако остается еще одна проблема, решению которой, по большому счету, и будет посвящено все дальнейшее изложение: как выбирать действие a_t на шаге t из набора возможных действий $A(s_t)$? Так мы приходим к понятию стратегии.

Определение 1.1.2 Набор вероятностей $\pi_t(a|s_t)$ выбора доступного действия a в момент времени t (в случае, когда агент находится в состоянии $s_t \in S$), называется стратегией агента.

Иными словами, в случае, когда в состоянии s_t в момент времени t доступно более одного действия в наборе $A(s_t)$, выбор совершаемого действия производится вероятностным образом: согласно стратегии $\pi_t(a|s_t)$. Как же задать такую стратегию, которая максимизирует ожидаемое совокупное вознаграждение? Это и есть тот самый «вопрос на миллион», который мы и будем обсуждать в дальнейшем.

1.2 Компромисс изучение-применение

Перед тем как переходить к рассмотрению конкретных примеров и задач, обратим наше внимание на так называемую проблему (или конфликт, компромисс) между изучением и применением («exploration-exploitation»). Принцип применения основывается на следующем предложении: на каждом шаге предлагается принять наилучшее (или наиболее выгодное) решение на основе имеющейся информации. Принцип изучения меняет концепцию: собрать как можно больше информации для (возможно) более успешного применения в дальнейшем. Идею упомянутого конфликта достаточно просто понять из рисунка [1](#).




Рис. 1: Компромисс «изучение-применение»

Предположим, что за один ход мышонок (наш агент) совершает одно перемещение (действие). Игра останавливается либо когда мышонок съедает сыр, либо когда попадает в ловушку, либо когда у него заканчивается запас ходов (пусть всего их, скажем, 10). Производится некоторое конечное количество экспериментов (игр), в результате чего подсчитывается общее количество добытого сыра. Ясно, что чем больше в результате всех игр добыто сыра – тем лучше. Кроме того, не добраться до сыра (истратить все ходы) и

не попасть в ловушку (не убить агента) – результат, который намного лучше, чем попасть в ловушку (то есть убить агента).

Из рисунка очевидно, что мышонку проще (и, вероятно, быстрее, а также безопаснее) всего каждый раз добираться до маленького кусочка сыра, расположенного поблизости, – так он гарантированно будет получать хоть и маленькую, но награду в результате каждой игры. При таком подходе (который часто нарекается подходом «лучше синица в руках») внушительные запасы сыра, лежащие рядом с ловушками, обесцениваются вовсе. Описанное является ничем иным, как принципом «применения».

С другой стороны, мышонки могут пожертвовать сиюминутным результатом (и, быть может, даже жизнью), чтобы исследовать окружающую среду и попытаться найти пусть и более сложную и опасную дорогу, но к более значимой награде, а значит в итоге увеличить добычу сыра (или награды) «в среднем».

Итак, тезисно компромисс между изучением и применением может быть охарактеризован следующими пунктами:

1. Необходимо получить достаточно информации об окружающей среде, чтобы решения (а значит и результаты) были наилучшими «в среднем».
2. Лучшая долгосрочная стратегия допускает (и даже обязательно включает в себя) краткосрочные потери.

Описанная проблема между изучением и применением – не что-то, созданное на пустом месте. Эта проблема регулярно возникает и в реальной жизни. Например, пусть вы решили ужинать в ресторане. Применение – это выбор проверенного ресторана, который стабильно не подводит ни качеством блюд, ни их ценой. Изучение – это выбор и опробование какого-то нового заведения: а вдруг там окажется лучше?

Ну что, надеемся, что как проблема, так и постановка задачи обучения с подкреплением ясна и прозрачна. Перейдем теперь к разбору одной из самых понятных и популярных задач – к задаче о k -руком бандите.

1.3 Постановка задачи о k -руком бандите

Как мы уже сказали, одним из самых простых примеров, иллюстрирующих идею обучения с подкреплением, является так называемая задача о k -руком бандите. Название задачи происходит из аналогии с игральным автоматом (хорошо известным, как «однорукий бандит»). В нашем же случае будем считать, что мы имеем дело с автоматом, имеющим k ручек.

Давайте для начала определимся: что в этой задаче является агентом, что средой, что стратегией и так далее. Агент – это человек, которому в каждый момент времени t в любом состоянии $s \in S$ доступно любое из k

одних и тех же действий – выбрать одну из k ручек. Конечно, каждый раз этот выбор осуществляется в соответствии с какой-то своей стратегией π_t . Выбрав действие a_t в момент времени t , агент получает заранее неизвестное вознаграждение r_{t+1} , диктуемое средой – k -руким автоматом, и переходит в следующее состояние.

Замечание 1.3.1 Отметим отдельно, что так как возможности (или набор возможных действий $A(s)$) агента в каждом состоянии $s \in S$ одинаковы – выбор одной из k ручек, то хочется сказать, что и состояния s агента на каждом шаге одинаковы (или вообще, что состояние всего одно). Такое предположение, вообще говоря, неверно, так как в каждом состоянии $s_t \in S$ в момент времени t , агент действует согласно некоторой, вообще говоря, различной стратегии π_t .

Теперь давайте обратимся к естественному вопросу: из каких соображений дергать за ручки? Если бы мы заранее знали ценность каждого действия, то логичной жадной (недальновидной) стратегией была бы такая: в момент времени t выбрать то действие (ту ручку), вознаграждение r_{t+1} за выбор которой будет максимальным. Мы же будущего не знаем, поэтому способны оценивать только результат наших прошлых действий: «дернул» за эту ручку – получил столько-то, за другую – столько-то, и так далее. В итоге оказывается разумным ввести следующее определение.

Определение 1.3.1 Пусть $q_0(a) \in \mathbb{R}$ – начальная оценка ценности действия a (устанавливается исследователем). Оценкой ценности действия a в момент времени $t \geq 1$ называется величина

$$q_t(a) = \begin{cases} q_0(a), & \text{действие } a \text{ не выбрано ни разу} \\ \frac{\sum_{i=0}^{t-1} r_{i+1} \mathbb{I}(a_i = a)}{\sum_{i=0}^{t-1} \mathbb{I}(a_i = a)}, & \text{иначе} \end{cases},$$

где $\mathbb{I}(a_i = a)$ – индикатор события $a_i = a$: он равен единице, если на i -ом шаге выбрано действие a , и нулю иначе.

Замечание 1.3.2 Написанное выражение (в случае, если действие a выбрано хотя бы один раз) – среднее арифметическое вознаграждений, полученных при выборе действия a до момента времени t .

Рассмотрим пример.

Пример 1.3.1 Пусть в процессе некоторой игры агент на каждом шаге совершает одно из двух возможных действий: a или b , в соответствии с некоторой стратегией, и на каждом шаге t получает некоторую награду r_{t+1} . Данные (с использованием введенных выше обозначений) представлены в таблице.

Шаг	Действие	Награда
$t = 0$	$a_0 = b$	$r_1 = 3$
$t = 1$	$a_1 = a$	$r_2 = 0$
$t = 2$	$a_2 = a$	$r_3 = 8$
$t = 3$	$a_3 = b$	$r_4 = 1$
$t = 4$	$a_4 = b$	$r_5 = 5$

Найдем оценки ценностей действий a и b на пятом шаге. Действие a было выбрано 2 раза, при этом были получены награды 0 и 8. Тогда оценка ценности действия a на пятом шаге может быть найдена следующим образом (как мы и говорили – как среднее арифметическое ранее полученных вознаграждений):

$$q_5(a) = \frac{0 + 8}{2} = 4.$$

Конечно, то же самое получится и при использовании «оригинального» соотношения из определения:

$$q_5(a) = \frac{\sum_{i=0}^{5-1} r_{i+1} I(a_i = a)}{\sum_{i=0}^{5-1} I(a_i = a)} = \frac{3 \cdot 0 + 0 \cdot 1 + 8 \cdot 1 + 1 \cdot 0 + 5 \cdot 0}{0 + 1 + 1 + 0 + 0} = 4.$$

Аналогичным образом найдем оценку ценности действия b на пятом шаге:

$$q_5(b) = \frac{3 + 1 + 5}{3} = 3.$$

Можно заметить, что оценка ценности действия a , посчитанная на пятом шаге, выше, чем оценка ценности действия b , однако все может измениться, если накопить большее количество информации о получаемых наградах.

Использование описанного подхода при оценке ценности влечет некоторые издержки с точки зрения вычислений и хранения информации. Нетрудно заметить, что для оценки ценности приходится хранить информацию обо всех полученных ранее вознаграждениях. Резонно задуматься, а существует ли менее затратный способ? Оказывается, существует. Он дается следующей леммой.

Лемма 1.3.1 (Рекуррентная формула оценки ценности) Пусть действие a в течение $(t-1)$ шагов выбрано ровно $n \leq (t-1)$ раз, $q_t(a)$ – оценка его ценности на шаге t . Если оно выбрано на шаге t , и за него получено вознаграждение r_{t+1} , то

$$q_{t+1}(a) = q_t(a) + \frac{1}{n+1} (r_{t+1} - q_t(a)),$$

иначе $q_{t+1}(a) = q_t(a)$, $q_0(a) \in \mathbb{R}$ – начальная оценка ценности.

Замечание 1.3.3 Использование введенной выше рекуррентной формулы позволяет хранить только два параметра: текущее значение ценности действия и число активаций этого действия.

Доказательство. Случай, когда на шаге t действие a не выбрано, очевиден – оценка ценности действия не меняется. Содержательным для рассмотрения является случай, когда на шаге t действие a все-таки выбрано. По определению,

$$q_t(a) = \frac{\sum_{i=0}^{t-1} r_{i+1} \mathbb{I}(a_i = a)}{\sum_{i=0}^{t-1} \mathbb{I}(a_i = a)} = \frac{\sum_{i=0}^{t-1} r_{i+1} \mathbb{I}(a_i = a)}{n},$$

где последнее равенство справедливо в силу условия: действие a до шага t было выбрано n раз. Но тогда $nq_t(a)$ – это сумма вознаграждений, полученных за выбор действия a до шага $(t-1)$ включительно. Раз действие выбрано и на шаге t , то, так как за него получено вознаграждение r_{t+1} (и теперь оно выбрано $(n+1)$ раз), для его оценки ценности имеем

$$\begin{aligned} q_{t+1}(a) &= \frac{1}{n+1} (r_{t+1} + nq_t(a)) = \frac{1}{n+1} (r_{t+1} + (n+1)q_t(a) - q_t(a)) = \\ &= q_t(a) + \frac{1}{n+1} (r_{t+1} - q_t(a)). \end{aligned}$$

□

Замечание 1.3.4 Помимо среднего арифметического полученных вознаграждений (в частности, чтобы динамически менять стратегию), часто используют и следующее правило получения $q_{t+1}(a)$:

$$q_{t+1}(a) = q_t(a) + \alpha_t (r_{t+1} - q_t(a)).$$

В частности, если $\alpha_t = \alpha$ – некоторая константа, то мы получаем экспоненциальное скользящее среднее:

$$q_{t+1}(a) = \alpha r_{t+1} + (1 - \alpha)q_t(a).$$

Это соотношение показывает, что если $\alpha \in (0, 1)$, то наиболее ценными оказываются сиюминутные награды (принцип «лучше синица в руках»), а если $\alpha > 1$ – наоборот. Сейчас мы на этом подробно останавливаться не будем.

1.4 Жадная стратегия

Итак, мы переходим к рассмотрению различных стратегий выбора действий на шаге t . Наверное, первый и самый наивный способ максимизации награды – это выбор на шаге t того (или тех действий), оценка ценностей которого (или которых) максимальна. Пусть A_t – множество действий в состоянии s_t , обладающих максимальной (и, как следствие, одинаковой) оценкой ценности. Говоря математическим языком, множество A_t – это множество

$$A_t = \operatorname{Arg} \max_{a \in A(s_t)} q_t(a).$$

Так как дальнейший выбор мы осуществляем только исходя из величины оценки ценности действия, а все действия из множества A_t на шаге t одинаково ценны (другие же не рассматриваются вовсе), то логично, что любое $a \in A_t$ имеет смысл выбирать равновероятно, а значит

$$\pi_t(a|s_t) = \begin{cases} \frac{1}{|A_t|}, & a \in A_t \\ 0, & a \notin A_t \end{cases},$$

где $|A_t|$ – количество элементов в множестве A_t . Таким образом, действия, обладающие максимальной оценкой ценности, выбираются с вероятностью $\frac{1}{|A_t|}$, остальные же действия игнорируются.

Определение 1.4.1 Стратегия, введенная выше, называется жадной стратегией.

Можно рассмотреть и полную противоположность жадной стратегии – так называемую абсолютно исследовательскую стратегию.

Определение 1.4.2 Если в результате обучения на каждом шаге t любое действие из множества $A(s_t)$ всех доступных в состоянии s_t действий выбирается с одинаковой вероятностью, то такая стратегия называется абсолютно исследовательской.

С точки зрения компромисса «изучение-применение» жадная стратегия – это в чистом виде применение, без какой-либо возможности изучения. Абсолютно исследовательская стратегия же скорее отвечает за постоянное изучение. Рассмотрим применение жадной стратегии на следующем примере.

Пример 1.4.1 Владелец небольшого магазина рассматривает возможности увеличения выручки. Он прочитал, что изменение расположения товара в магазине может стимулировать покупателей к импульсивным покупкам. Например, если расположить печенье рядом с чаем, то вероятность покупки печенья увеличивается, что увеличивает выручку. Владелец решил опробовать три различные конфигурации и понаблюдать за выручкой магазина.

Итак, определимся что есть что. Пусть «ручка» – это одна из трех выбранных конфигураций (a , b , c), t – номер дня, в который проводится эксперимент, награда – сумма потраченных покупателями денег в течение дня (выручка магазина). Пусть каждая игра состоит из 1000 итераций (шагов) (по сути – это количество дней, в течение которых проводится эксперимент). Награды в случае выбора конфигурации a , b или c – это выборки из генеральных совокупностей ξ_1 , ξ_2 , ξ_3 , имеющих распределения $N_{2,1}$, $N_{2.5,1}$ и $N_{3,1}$, соответственно. Говоря формально, награды в рассматриваемом примере могут быть отрицательными, и могут трактоваться либо как ошибки в данных, либо как убытки магазина: утерянный, просроченный, разбитый товар, и так далее.

Итак, как же поступает агент при использовании жадной стратегии? Пусть $q_0(a) = q_0(b) = q_0(c) = 0$. Так как в момент времени $t = 0$ оценки ценности всех действий (конфигураций) одинаковы, то выбор среди них производится случайным образом, а значит любая из трех конфигураций будет выбрана равновероятно. В итоге, стратегия на нулевом шаге такова:

$$\pi_0(a|s_0) = \pi_0(b|s_0) = \pi_0(c|s_0) = \frac{1}{3}.$$

Пусть, скажем, выбрана конфигурация c (то есть $a_0 = c$). Тогда оценка ценности этой и только этой конфигурации станет положительной (предполагается, что выручка магазина в первый день все же положительна), а значит, в соответствии с алгоритмом, на первой итерации будет снова выбрана конфигурация c (то есть $a_1 = c$), и так далее, а значит стратегия такова:

$$\pi_t(c|s_t) = 1, \quad t \geq 1.$$

В итоге, в нашем примере (согласно жадной стратегии) будет всегда выбираться та конфигурация, которая была выбрана (случайным образом) на нулевом шаге.

На рисунке 2 представлены результаты трех игр. Синяя кривая отвечает ситуации, когда в первой игре первым было выбрано действие $a_0 = c$ и, как мы только что отметили, оно же выбиралось на всех последующих шагах ($a_t = c$, $t \in \{0, 1, \dots, 999\}$). Сам график показывает среднее значение

награды или, что в нашем случае одно и то же, оценку ценности действия s на каждом шаге.

Во второй игре на первом шаге выбор пал на конфигурацию a , то есть $a_0 = a$ (красная кривая). График снова показывает величину средней награды при таком выборе начальной конфигурации (опять же, $a_t = a$, $t \in \{0, 1, \dots, 999\}$).

В третьей игре первым (как и последующими) было выбрано действие b . Значения средней награды в этом случае изображены оранжевым цветом. Видно, что максимально возможное среднее значение награды достигнуто только в одном из трех случаев. Кроме того, в одном из трех случаев достигнуто минимальное среднее значение награды.

«Игры», описанные в данном примере, на практике могут быть реализованы следующим образом: есть три магазина некоторой сети, находящиеся в одинаковых условиях. Каждый из них независимо в течение 1000 дней использует единственную конфигурацию и оценивает среднюю выручку. Далее происходит сравнение оценок и делается вывод о том, какая конфигурация работает лучше (если такая конфигурация имеется).

Понятно, что выбор лучшей начальной конфигурации в нашем примере – дело случая. Именно поэтому, с точки зрения оценки самой стратегии, нам интересно, как ведет себя алгоритм «в среднем». Для этого проводят серию игр. На рисунке 2 черным цветом иллюстрируется среднее значение средней награды по трем играм на каждом шаге. На рисунке 3 представлены результаты применения жадной стратегии при проведении 1000 игр по 1000 итераций в каждой. Черной линией отмечено среднее значение средней награды по всем играм. В отношении примера с конфигурациями магазина, описанный подход может быть реализован следующим образом: есть 1000 магазинов некоторой сети, находящихся в одинаковых условиях. В каждом из магазинов проводится оценка одной из трех конфигураций в течение 1000 дней. Тогда при использовании жадной стратегии, «в среднем» каждый магазин будет генерировать ежедневную выручку на уровне 2.5 единиц.

Замечание 1.4.1 В дальнейшем, для сравнения стратегий мы будем также проводить 1000 игр по 1000 итераций в каждой, а результаты усреднять. Поскольку полученные результаты не будут являться результатами применения непосредственно стратегии, а будут являться усреднением по тысячекратному применению стратегии, то будем использовать термин алгоритм (например, жадный алгоритм).

Конечно, существенным недостатком жадного алгоритма в рассмотренном примере является то, что исследование среды прекращается после первого же шага, что, конечно, серьезно сказывается на результатах. Как мы



img/Average_check_estimation.png

Рис. 2: Средняя выручка в зависимости от выбранной конфигурации

уже отмечали, на рисунке [2](#) видно, что «жадный» принцип в рассмотренном примере с магазинами только в одном из трех случаев приводит к максимальной возможной средней выручке. Более того, в одном из трех случаев он приводит даже к минимально возможной средней выручке. Причина этому – запрет на какое-либо исследование. Исправить эту ситуацию помогает так называемая ε -жадная стратегия.