


Содержание

1	Понятие обучения с подкреплением	2
1.1	Базовые определения и постановка задачи	2
1.2	Компромисс изучение-применение	5
1.3	Постановка задачи о k -руком бандите	6
1.4	Жадная стратегия	10
1.5	ε -жадная стратегия	13
1.6	Softmax-стратегия	17
1.7	Метод UCB (Upper Confidence Bound)	19
1.8	Оптимистичные начальные оценки	22
2	Общая постановка задачи	24
2.1	Взаимосвязь агента и окружающей среды	24
2.2	Функции ценности действий и состояний	32
2.3	Пример	35
2.4	Оценка стратегий	39
2.5	Оптимальные стратегии	46
2.6	SARSA	55
2.7	Q-обучение	60
2.8	Пример	63
2.9	Резюме	65
3	Заключение	65



1.5 ε -жадная стратегия

Итак, как мы уже поняли ранее, для получения более приемлемого результата скорее всего имеет смысл использовать что-то вроде смеси абсолют-


The image is a placeholder for a diagram illustrating a greedy algorithm. It is represented by the text 'img/greedy.png' within a rectangular frame.

Рис. 3: Иллюстрация жадного алгоритма

но исследовательской и жадной стратегий. Ведь чем лучше агент понимает, как устроена среда, тем более выгодные действия он может совершать. В то же время, исследование ради исследования – малоинтересная задача, так что «жадность» полностью отключать, конечно же, нельзя, ведь принцип: «если дают, надо брать», пока еще никто не отменял.

Определение 1.5.1 Пусть $0 < \varepsilon < 1$. Стратегия, $\pi_t(a|s_t)$, которая в момент времени t с вероятностью $(1 - \varepsilon)$ ведет себя как жадная, а с вероятностью ε как абсолютно исследовательская, называется ε -жадной.

Таким образом, введенная стратегия – это попытка обеспечить компромисс

между применением и изучением. Полезно отметить, что при $\varepsilon = 0$ или $\varepsilon = 1$ (хотя это и запрещено в определении), ε -жадная стратегия становится жадной и абсолютно исследовательской, соответственно.

Для практики бывает полезным следующее задание ε -жадной стратегии:

$$\pi_t(a|s_t) = \begin{cases} \frac{1-\varepsilon}{|A_t|} + \frac{\varepsilon}{|A(s_t)|}, & a \in A_t \\ \frac{\varepsilon}{|A(s_t)|}, & a \notin A_t \end{cases},$$

где

$$A_t = \operatorname{Arg} \max_{a \in A(s_t)} q_t(a).$$

Замечание 1.5.1 Давайте поясним, почему написанные формулы согласованы с данным выше определением. Ответим на вопрос: какова вероятность выбрать действие $a \in A_t$? Это действие выбирается с вероятностью $\frac{1}{|A_t|}$, если используется жадная стратегия, и с вероятностью $\frac{1}{|A(s_t)|}$, если используется абсолютно исследовательская стратегия. В силу того, что жадная стратегия выбирается с вероятностью $(1 - \varepsilon)$, а абсолютно исследовательская – с вероятностью ε , получаем следующую вероятность выбрать действие $a \in A_t$:

$$\frac{1-\varepsilon}{|A_t|} + \frac{\varepsilon}{|A(s_t)|}.$$

Аналогично, действие $a \notin A_t$ может быть выбрано только в случае, когда выбрана абсолютно исследовательская стратегия, причем в этом случае оно выбирается с вероятностью $\frac{1}{|A(s_t)|}$. Так как абсолютно исследовательская стратегия выбирается с вероятностью ε , то вероятность выбрать действие $a \notin A_t$ равна

$$\frac{\varepsilon}{|A(s_t)|}.$$

Покажем, что введенное определение корректно, то есть что введенная «стратегия» является стратегией в смысле введенного ранее определения.

Лемма 1.5.1 ε -жадная стратегия является стратегией.

Доказательство. Достаточно доказать, что

$$\sum_{a \in A(s_t)} \pi_t(a|s_t) = 1.$$

Это и правда так, ведь

$$\sum_{a \in A(s_t)} \pi_t(a|s_t) = |A_t| \left(\frac{1-\varepsilon}{|A_t|} + \frac{\varepsilon}{|A(s_t)|} \right) + (|A(s_t)| - |A_t|) \left(\frac{\varepsilon}{|A(s_t)|} \right) = 1.$$

□

Сравнение жадного и ε -жадного алгоритмов для примера с различными конфигурациями магазина (1000 игр по 1000 итераций в каждой) представлено на рисунке 4. Отметим, что для большей информативности этот и последующие графики будут строиться, начиная с шага $t = 1$. Можно заме-



img/eps_greedy.png

Рис. 4: Сравнение ε -жадных алгоритмов

тить, что при использовании различных значений ε , результаты несколько отличаются. Видно, например, что при значении $\varepsilon = 0.2$ (то есть в случае, когда дается больше «свободы» абсолютно исследовательской стратегии), высокие значения средней награды достигаются намного быстрее, чем в случае $\varepsilon = 0.1$ и $\varepsilon = 0.01$. Однако, когда ценности действий изучены достаточно (начиная примерно с трехсотого шага), алгоритм при $\varepsilon = 0.2$ начинает проигрывать случаю $\varepsilon = 0.1$ из-за того, что доля его исследовательских действий выше и действительно оптимальное действие (оценка ценности которого уже достаточно точна) выбирается реже. Случаю $\varepsilon = 0.01$ нужно гораздо больше времени на оценку ценностей всех действий. Потенциал этого алгоритма раскрывается в случае использования не 1000, а 10000 шагов (рисунок 5).

Можно заметить, что в конечном итоге при $\varepsilon = 0.01$ значение средней награды оказывается выше конкурентов, начиная, примерно, с шага $t = 8000$.

Замечание 1.5.2 Важно отметить, что каждый из рассмотренных ε -жадных алгоритмов работает куда лучше, чем жадный алгоритм. Более того, значения средней награды в каждом из рассмотренных случаев достаточно быстро сходятся к значениям, близким к среднему максимуму – к 3. Скачкообразное поведение некоторых графиков при малом количестве шагов обуславливается неточными сведениями об оценке ценности действий (сведения просто еще не успели накопиться). Для их уточнения действия выбираются в большей степени хаотично, что и влечет скачки средней награды.


Замечание 1.5.3 Напоследок отметим следующее эвристическое замечание: со временем (то есть с ростом t) параметр ε имеет смысл уменьшать, ведь оценки ценностей действий становятся точнее и имеет смысл большее внимание уделить применению, нежели изучению. Например, в качестве зависимости величины ε от времени t можно рассматривать функцию вида

$$\varepsilon(t) = \frac{1}{1 + t\beta},$$

где t – текущий момент времени, а $\beta \in (0, 1)$ – некоторый коэффициент, отвечающий за скорость уменьшения ε . В качестве β можно брать, например, $\frac{1}{k}$, где k – число рукоятей бандита. Выбор функции, конечно, отдается на откуп исследователю.

1.6 Softmax-стратегия

Использование ε -жадной стратегий имеет определенный недостаток. В случае, когда идет процесс «изучения», действия выбираются с одинаковой вероятностью, что явно не лучшим образом сказывается на конечной цели –



img/eps_greedy_10k.png

Рис. 5: Сравнение ε -жадных алгоритмов

наибольшей сумме поощрений (ведь действия с высокими и низкими оценками ценности имеют одинаковые шансы быть выбранными). Принцип, которым руководствуется softmax-стратегия, можно описать следующим образом: уменьшение потерь при исследовании на итерации t за счёт более редкого выбора действий a , которые имеют небольшую оценку ценности $q_t(a)$. Чтобы этого добиться, для каждого действия вычисляется свой «весовой коэффициент», на базе которого и происходит выбор действия. Точнее, стратегия дается следующим определением.

Определение 1.6.1 *Стратегия, при которой вероятность выбора дей-*

ствия $a_t \in A(s_t)$ в момент времени t равна

$$\pi_t(a|s_t) = \frac{e^{q_t(a)/\tau}}{\sum_{a \in A(s_t)} e^{q_t(a)/\tau}}, \quad \tau > 0,$$

называется *softmax-стратегией*.

Параметр $\tau > 0$, называемый еще и температурой, является параметром модели. При больших значениях τ стратегия становится более исследовательской, при малых – приближается к жадной. На рисунке 6 (рисунок снова строится при $t \geq 1$) представлено сравнение ε -жадного алгоритма с параметром $\varepsilon = 0.1$ и алгоритма softmax при различных значениях температуры τ . Легко понять, что конкретно в нашем случае ε -жадный алгоритм показывает лучший результат. При этом выбор того или иного метода обычно отдается на откуп исследователю. Заметим также, что при $\tau = 0.01$ softmax-алгоритм очень близок к жадному.


Замечание 1.6.1 Введенное выше распределение вероятностей в физике часто называется распределением Гиббса (или Больцмана). Еще раз отметим, что при $\tau \rightarrow +\infty$ мы получаем почти одинаковые вероятности выбора действий $a \in A(s_t)$, а значит стратегия стремится к абсолютно исследовательской. В случае же, когда $\tau \rightarrow 0+$, стратегия стремится к жадной, так как среди всех экспонент больший вес имеет та, для которой $q_t(a)$ больше.

Замечание 1.6.2 Как и в случае ε -жадной стратегии, параметр τ имеет смысл уменьшать со временем. Как это делать и делать ли вообще – вопросы, которые отдаются на откуп исследователю.

1.7 Метод UCB (Upper Confidence Bound)

Рассмотрим еще один способ нахождения компромисса при решении проблемы «изучение-применение». Этот метод получил название метода максимальной верхней оценки (Upper Confidence Bound (UCB)). Идею метода можно описать следующим образом: чем реже было выбрано какое-то действие a , тем менее точной является оценка его ценности (ведь действие мало изучено). Чтобы решить описанную проблему, кажется резонным рассмотреть в качестве новой оценки ценности действия a сумму текущей оценки ценности и «близости» этой оценки к истинному значению – правую границу некоторого доверительного интервала для истинной ценности. Опишем метод формально.

Пусть агент находится в состоянии s_t , $t \geq 0$. Пусть $N_0(a) = 0$, $N_t(a)$ – количество раз, которое было выбрано действие a до шага $(t-1)$ включительно ($t \geq 1$).



img/softmax.png

Рис. 6: Сравнение ε -жадного алгоритма и алгоритма softmax

1. Если существует $a \in A(s_t)$ такое, что $N_t(a) = 0$, тогда

$$A_t = \{a \in A(s_t) : N_t(a) = 0\}$$

и стратегия выбора $a_t \in A_t$ такова:

$$\pi_t(a|s_t) = \begin{cases} \frac{1}{|A_t|}, & a \in A_t \\ 0, & a \notin A_t \end{cases}.$$

2. Иначе

$$A_t = \operatorname{Arg\,max}_{a \in A(S_t)} \left(q_t(a) + \delta \sqrt{\frac{\ln t}{N_t(a)}} \right), \quad \delta > 0,$$

и стратегия выбора $a_t \in A_t$ такова:

$$\pi_t(a|s_t) = \begin{cases} \frac{1}{|A_t|}, & a \in A_t \\ 0, & a \notin A_t \end{cases}.$$

Иными словами, если действие не было выбрано ни разу, то оно и выбирается в качестве следующего (если таких действий несколько, то выбор среди них осуществляется случайным образом). Если таких действий нет, то на выбор влияет, с одной стороны, ценность действия $q_t(a)$, а с другой – степень его исследованности. Параметр $\delta > 0$ в некотором смысле отвечает за вклад последней. Подробные пояснения могут быть найдены в дополнительных материалах.

Лемма 1.7.1 Пусть $X_1, X_2, \dots, X_n$ – выборка из генеральной совокупности ξ , причем $X_i \in [0, 1]$,

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Тогда справедливо неравенство Хёфдинга

$$\mathbb{P}(\bar{X} - \mathbb{E}\xi \geq \varepsilon) \leq e^{-2n\varepsilon^2}.$$

Пусть $U \geq 0$. Перепишав неравенство в наших обозначениях, а также пользуясь симметричностью последнего, получим

$$\mathbb{P}(\mathbb{E}\xi - q_t(a) \geq U) \leq e^{-2N_t(a)U^2}.$$

Или иначе

$$\mathbb{P}(\mathbb{E}\xi \geq q_t(a) + U) \leq e^{-2N_t(a)U^2}.$$

Итак, мы оценили сверху вероятность того, что истинная «ценность» больше, чем сумма оценки ценности и U – числа, называемого upper confidence bound (UCB). Обозначим

$$\mathbf{p} = e^{-2N_t(a)U^2},$$

откуда

$$\ln \mathbf{p} = -2N_t(a)U^2 \implies U = \sqrt{\frac{\ln \mathbf{p}}{-2N_t(a)}}.$$

p можно выбрать, например, как функцию от t , при этом разумно, чтобы

$$p(t) \xrightarrow{t \rightarrow +\infty} 0.$$

Тогда, положив

$$p = \frac{1}{t^{2\delta^2}},$$

получим

$$U = \delta \sqrt{\frac{\ln t}{N_t(a)}},$$

что и используется в предложенном выше алгоритме.

Замечание 1.7.1 В условиях неравенства Хёфдинга предполагается, что все элементы выборки $X_i \in [0, 1]$, поэтому для корректности применения метода рекомендуется проводить предварительную нормировку.

На рисунке 7 представлены результаты сравнения метода UCB с различными параметрами δ и ε -жадного алгоритма. Можно заметить, что в наблюдаемых условиях чем больше δ , тем раньше алгоритм выходит на условное «плато продуктивности». В случае $\delta = 1.5$ доля исследовательских действий меньше, чем при $\delta = 2$ и $\delta = 3$, поэтому требуется больше времени на исследование, что, однако, положительно сказывается в более длительной перспективе.


Замечание 1.7.2 Отметим также, что параметр δ опять-таки имеет смысл уменьшать со временем, для того, чтобы смещать акцент с изучения на применение и увеличивать таким образом среднюю награду.

1.8 Оптимистичные начальные оценки

Во всех ранее рассмотренных случаях выбор того или иного действия опирался на оценку его ценности. При этом начальные оценки для всех действий предполагались равными из-за того, что агент на начальном этапе не обладает какой-либо информацией о ценностях тех или иных действий. При использовании, например, ε -жадного алгоритма оценки ценности действий уточняются по мере выбора самих действий.

Похожая идея используется и в методе, который получил название «метод оптимистичных начальных оценок». Оптимизм, следующий из названия, заключается в том, что при инициализации каждому действию устанавливается заведомо завышенное значение ценности. Поясним сказанное на рассматриваемом нами примере.

Напомним, что значения поощрений генерировались из генеральных совокупностей, имеющих распределения $N_{2,1}$, $N_{2.5,1}$, $N_{3,1}$. Таким образом, если в



img/UCB.png

Рис. 7: Сравнение ε -жадного и UCB алгоритмов

качестве начальных значений положить $q_0(a) = q_0(b) = q_0(c) = 10$ (что явно выше как 2, так и 2.5, и 3), то такие оценки можно считать даже слишком оптимистичными – они будут уменьшаться по мере обучения модели. Выбор действий будем производить при помощи жадной стратегии.

Рассмотрим несколько шагов. Оценки ценности будем заносить в соответствующую таблицу.

Шаг	$q_t(a)$	$q_t(b)$	$q_t(c)$
$t = 0$	10	10	10

Поскольку оценки ценностей всех действий одинаковы, выбирается про-

извольное действие, например, действие c . Пусть награда составит $r_1 = 2.8$, тогда

$$q_1(c) = q_0(c) + \frac{1}{1+1} (r_1 - q_0(c)) = 10 + \frac{(2.8 - 10)}{2} = 6.4.$$

Добавим значение в таблицу

Шаг	$q_t(a)$	$q_t(b)$	$q_t(c)$
$t = 0$	10	10	10
$t = 1$	10	10	6.4

Теперь, согласно жадному алгоритму, агент будет выбирать одно из действий a или b , так как их текущая оценка ценности выше. Пусть выбрано действие a и получена награда $r_2 = 2.2$. Тогда

$$q_2(a) = q_1(a) + \frac{1}{1+1} (r_2 - q_1(a)) = 10 + \frac{(2.2 - 10)}{2} = 6.1.$$

Занесем полученный результат в таблицу.

Шаг	$q_t(a)$	$q_t(b)$	$q_t(c)$
$t = 0$	10	10	10
$t = 1$	10	10	6.4
$t = 2$	6.1	10	6.4

Следующим, очевидно, будет выбрано действие b . Продолжая, агент будет переключаться между действиями, будучи разочарованным получаемой наградой. При этом все действия будут опробованы некоторое количество раз, что позволит построить оценки, достаточно близкие к истинным значениям.

Нетрудно заметить, что в силу «оптимизма» на первых шагах происходит изучение, а когда оценки ценности уточнены, акцент смещается на применение.

Сравнение жадного алгоритма с оптимистичными начальными оценками и ранее рассмотренных алгоритмов (1000 игр по 1000 шагов, построение при $t \geq 1$) представлено на рисунке [8](#).

Можно заметить, что в самом начале обучения оптимистичный алгоритм проигрывает ε -жадному с убывающим ε , так как «изучает» среду, однако по прошествии времени демонстрирует куда более высокие результаты.