

Содержание

1	Понятие обучения с подкреплением	2
1.1	Базовые определения и постановка задачи	2
1.2	Компромисс изучение-применение	5
1.3	Постановка задачи о k -руком бандите	6
1.4	Жадная стратегия	10
1.5	ε -жадная стратегия	13
1.6	Softmax-стратегия	17
1.7	Метод UCB (Upper Confidence Bound)	19
1.8	Оптимистичные начальные оценки	22
2	Общая постановка задачи	24
2.1	Взаимосвязь агента и окружающей среды	24
2.2	Функции ценности действий и состояний	32
2.3	Пример	35
2.4	Оценка стратегий	39
2.5	Оптимальные стратегии	46
2.6	SARSA	55
2.7	Q-обучение	60
2.8	Пример	63
2.9	Резюме	65
3	Заключение	65

2 Общая постановка задачи

2.1 Взаимосвязь агента и окружающей среды

Ранее, говоря о k -руких бандитах, мы уже описали «на пальцах» схему взаимодействия агента и среды. Строго говоря, чуть ли не самое важное в



img/optimistic.png

Рис. 8: Сравнение различных алгоритмов

описанном ранее – это стратегия выбора действия агентом в момент времени t . Давайте еще раз подробно обсудим весь процесс.

В каждый дискретный момент времени $t \in \{0, 1, 2, \dots, n\}$, $n \in \mathbb{N} \cup \{0, \infty\}$, агент находится в некотором состоянии $s_t \in S$, где S – множество всех возможных состояний. Согласно стратегии $\pi_t(a|s_t)$, агент выбирает одно из возможных действий $a_t \in A(s_t)$, где $A(s_t)$ – множество доступных агенту действий в состоянии s_t . В случае, если на любом шаге агенту доступны все действия, будем писать $a_t \in A$, где $A = \bigcup_{s \in S} A(s)$ – множество всех возможных действий. После совершения действия, агент получает награду $r_{t+1} \in \mathbb{R}$

и переходит в состояние s_{t+1} . В итоге, вся история обучения может рассматриваться как последовательность троек вида (состояние, действие, награда):

$$s_0, a_0, r_1,$$

$$s_1, a_1, r_2,$$

...

Замечание 2.1.1 Отметим отдельно, что так как действия выбираются согласно стратегии (не детерминировано, а вероятно), то как вознаграждение, так и следующее состояние агента тоже являются в некотором смысле случайными. Поэтому можно говорить, что среда генерирует как награду r_{t+1} за действие a_t , так и следующее состояние s_{t+1} агента, в зависимости от последовательности ранее выбранных действий и состояний. А значит, s_t и r_t являются случайными величинами, причем

$$s_{t+1} \sim p(s|s_t, a_t, r_t, s_{t-1}, a_{t-1}, r_{t-1}, \dots, s_0, a_0),$$

$$r_{t+1} \sim p(r|s_t, a_t, r_t, s_{t-1}, a_{t-1}, r_{t-1}, \dots, s_0, a_0),$$

где p – какое-то вероятностное распределение.

Итого оказывается, что рассматриваемая тройка (состояние агента, стратегия выбора действия, награда за выбранное действие) на каждом последующем шаге зависит от каждого предыдущего шага. Такая постановка оказывается чрезвычайно сложной как с точки зрения теории (многомерные совместные распределения), так и с точки зрения практики: хранение огромного количества предшествующей информации. В рамках данной лекции мы упростим себе задачу и будем считать, что следующий шаг зависит только от текущего положения дел, а прошлый опыт не учитывается вовсе. Введем следующее определение.

Определение 2.1.1 Марковским процессом принятия решений (МППР) называется четверка (S, A, R, P) , где

1. S – множество возможных состояний агента.
2. A – множество доступных действий агента.
3. $R : S \times A \rightarrow \mathbb{R}$ – функция поощрения (или ожидаемое вознаграждение) при переходе из состояния s в состояние s' при выборе действия a .
4. $P : S \times A \rightarrow \Pi(S)$ – функция перехода между состояниями, $\Pi(S)$ – множество распределений вероятностей над S ,

причем вероятности последующих переходов не зависят от истории предыдущих переходов, то есть

$$s_{t+1} \sim \kappa(s_t, a_t) \in \Pi(S),$$

$$P_{\kappa}(s_{t+1} = s' | s_t, a_t, r_t, s_{t-1}, a_{t-1}, r_{t-1}, \dots, s_0, a_0) = P_{\kappa}(s_{t+1} = s' | s_t, a_t).$$

Итак, $\kappa(s_t, a_t)$ – это распределение вероятностей перехода в некоторое состояние из состояния s_t в результате совершения действия a_t , а МППР – это модель, при использовании которой у агента в каком-то смысле «отсутствует память»: вероятность перехода в состояние s' на шаге t зависит только от текущего состояния s_t и выбранного действия a_t .

Замечание 2.1.2 (!) Прежде чем пояснить каждый пункт определения детальнее, отметим следующий важный момент. Обучение с подкреплением использует в своей основе МППР, но не описывается «вчистую» таковым. Отличие заключается в том, что агент в каждом состоянии s выбирает некоторое действие $a \in A(s)$ с вероятностью $\pi(a|s)$ (то есть действует в соответствии с некоторой стратегией). Мы будем впредь считать стратегию агента неотъемлемой частью МППР, не обговаривая это отдельно.

Теперь поясним каждый пункт определения детальнее. Понятия множества состояний агента и множества доступных действий нам уже известны. R – это функция, которая выдает ожидаемое вознаграждение при выборе действия $a \in A(s_t)$, находясь в состоянии s_t . Грубо говоря, подавая на вход текущее состояние и выбранное действие, функция R выдает число – ожидаемое вознаграждение при таком «ходе». Функция P же выдает распределение вероятностей перехода между состояниями в случае, когда агент находится в состоянии s_t и выбирает действие a_t .

Пример 2.1.1 На рисунке 9 приведен пример МППР.

В рассматриваемом случае агентом является ребенок, который может находиться в одном из пяти состояний (большие кружки):

s_1 : Игра.

s_2 : Прием пищи.

s_3 : Плач.

s_4 : Прогулка.

s_5 : Сон.

Будем считать, что всего агенту доступно лишь 4 действия (маленькие кружки)

a_1 : Играть.

a_2 : Попросить поест.




Рис. 9: МППР

a_3 : Пойти гулять.

a_4 : Лечь спать.

Итак, как же прочитать и понять информацию, заложенную на рисунке **9**? Стрелки, выходящие из кругов, отвечающих состояниям, приводят нас к доступным в этом состоянии действиям (числа p около этих стрелок диктуются стратегией агента: они показывают вероятность выбора действия, к которому идет стрелка, находясь в состоянии, из которого идет стрелка). Далее, выбрав действие, возникает распределение вероятностей над S : числа P около стрелок, выходящих из кругов, отвечающих действиям, показывают, с какой вероятностью и в какое состояние агент может перейти, а также какое вознаграждение R он может получить. Так, из состояния s_1 , выбрав действие a_1 (с вероятностью 0.9), агент переходит в состояние s_3 с вероятностью $1/3$, получая вознаграждение $r = -10$, и возвращается в состояние s_1 с вероятностью $2/3$, получая при этом вознаграждение -2 . Распределение вероятностей перехода из со-

стояния s_1 при выборе действия a_1 – это и есть распределение $\kappa(s_1, a_1)$ из определения МППР. В нашем примере оно задается следующей таблицей:

	s_1	s_3
P	2/3	1/3

В то же время, выбрав в том же состоянии действие a_2 (с вероятностью 0.1), автоматически осуществляется переход (с вероятностью $P = 1$) в состояние s_2 с наградой $r = -2$, то есть распределение $\kappa(s_1, a_2)$ задается таблицей

	s_2
P	1

Ну и так далее.

В общем случае множества состояний S и действий A могут быть как конечными, так и бесконечными. Мы в нашей лекции ограничимся случаем, когда оба этих множества конечны. Такие процессы имеют даже отдельное название.

Определение 2.1.2 Марковский процесс принятия решений, в котором множества A и S являются конечными, называется *финитным*.

Отметим еще одно важное определение.

Определение 2.1.3 Если на шаге T среда переходит в состояние, при котором взаимодействие агента и среды (игра) прекращается, то это состояние называется *терминальным*.

Например, в игре «крестики-нолики» (с конечным размером поля) терминальное состояние достигается либо когда один из игроков одерживает победу, либо когда все ячейки таблицы заполнены.

Пример 2.1.2 Немного изменим рассмотренный ранее пример – изменилось состояние s_5 . Теперь это состояние оказывается терминальным – из него нет ни одного доступного действия. Родители могут отдохнуть :)

Итак, основные определения введены. Теперь осталось понять: а что же мы будем оценивать в результате «игры»?

Определение 2.1.4 Пусть мы находимся на шаге t , а взаимодействие агента и среды предполагает бесконечное число шагов. Тогда ожидаемой выгодой после шага t называется величина

$$G_t = r_{t+1} + r_{t+2} + \dots = \sum_{k=0}^{\infty} r_{t+k+1}$$




Рис. 10: МППР с терминальным состоянием

Если рассматривается взаимодействие, предполагающее достижение терминального состояния за конечное число шагов $t \in \{0, 1, 2, \dots, T\}$, то ожидаемой выгодой называется величина

$$G_t = r_{t+1} + r_{t+2} + \dots + r_T$$

Наверное, введенное определение – одно из самых естественных: нет ничего проще, чем просто-напросто сложить все получаемые в дальнейшем награды (правда, пока неизвестно какие).

Замечание 2.1.3 Отметим отдельно, что бесконечное взаимодействие агента и среды (то есть $T = +\infty$) – вовсе не выброс, а весьма частая ситуация. Кроме того, зачастую так называемое «время жизни» агента не определено. Например, выход из лабиринта может закончиться за конечное число ходов (с заранее неизвестным (!) количеством), а может не закончиться вовсе (агент заблудился).

В то же время, максимизация суммарной награды – достаточно наивная вещь. Например, можно долго собирать «плюсики», медленно путешествуя в сторону выхода из лабиринта, хотя, казалось бы, логичнее выбраться из него как можно быстрее, то есть использовать принцип: «чем раньше прибыль, тем лучше». Тогда куда более логичным кажется использование следующего понятия.

Определение 2.1.5 Пусть мы находимся на шаге t , а взаимодействие агента и среды предполагает бесконечное число шагов. Тогда приведенной ожидаемой выгодой называется величина

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} \dots = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1},$$

где величина $\gamma \in [0, 1]$ называется коэффициентом дисконтирования.

Если рассматривается взаимодействие, предполагающее достижение терминального состояния за конечное число шагов $t \in \{0, 1, 2, \dots, T\}$, то приведенной ожидаемой выгодой называется величина

$$G_t = r_{t+1} + \gamma r_{t+2} + \dots + \gamma^{T-t-1} r_T.$$

Приведенную ожидаемую выгоду можно еще назвать принципом «обесценивания награды». В соответствии с описанным подходом, агент пытается выбирать действия таким образом, чтобы сумма обесценивающихся получаемых наград была наибольшей. То есть на каждом шаге агент пытается выбрать такое действие a_t , чтобы наибольшая возможная награда не обесценилась слишком сильно (последнее происходит, конечно, из-за промедления).

Можно описать это и следующим образом. Коэффициент дисконтирования γ отвечает за то, насколько важны будущие выигрыши, то есть регулирует «дальновидность» агента. Если $\gamma = 0$, то агент не обращает внимания на все последующие выигрыши и стремится максимизировать текущий. В перспективе это может снизить ожидаемую выгоду. В то же время, значения γ близкие к единице увеличивают значимость будущих вознаграждений.

Замечание 2.1.4 Заметим, что ожидаемая выгода как в случае конечного, так и в случае бесконечного числа шагов, получается из приведенной при $\gamma = 1$.

Справедлива следующая лемма.

Лемма 2.1.1 Если $\gamma \in (0, 1)$ и последовательность $r_{t+1}, r_{t+2}, r_{t+3}, \dots$ ограничена, то приведенная выгода

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

имеет конечное значение.

Доказательство. Так как последовательность $\{r_{t+k+1}\}_{k=0}^{\infty}$ ограничена, то $|r_{t+k+1}| \leq C$. Тогда

$$|\gamma^k r_{t+k+1}| \leq C\gamma^k.$$

Так как ряд с общим членом γ^k при $\gamma \in (0, 1)$ сходится (как геометрическая прогрессия), то исходный ряд сходится абсолютно, а значит сходится. $\square$

2.2 Функции ценности действий и состояний

Для того, чтобы агент понимал, как следует вести себя при взаимодействии со средой, то есть какой стратегии придерживаться, должен быть некоторый аппарат, описывающий состояния агента. В обучении с подкреплением применяется подход, в котором каждому состоянию присваивается некоторая численная величина – ценность этого состояния. Ценность состояния призвана охарактеризовать это состояние с точки зрения приведенной выгоды.

Определение 2.2.1 Пусть π – стратегия агента. Функцией ценности состояния s при использовании стратегии π называется функция вида

$$v_{\pi}(s) = E_{\pi}(G_t | s_t = s) = E_{\pi} \left(\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s \right), \quad s \in S.$$

Функция ценности состояний определяет среднее значение приведенной выгоды, если мы начинаем в состоянии s и следуем стратегии π . Зная ценность каждого состояния, логично использовать такую стратегию, которая приведет нас к состоянию с максимальной ценностью.

Замечание 2.2.1 Формально (в определении функции ценности) перед нами не что иное, как условное математическое ожидание – функция от состояния $s \in S$. Меняя состояние s , меняется стратегия $\pi(a|s)$, тем самым меняется и $v_{\pi}(s)$.

К вопросу оценки ценности можно подойти и более педантично: оценивать приведенную выгоду, стартуя не столько из состояния s , но и выбрав действие a . Тем самым мы приходим к понятию ценности действия.

Определение 2.2.2 Пусть π – стратегия агента. Функцией ценности действия a в состоянии s при использовании стратегии π называется функция

$$q_{\pi}(s, a) = E_{\pi}(G_t | s_t = s, a_t = a) = E_{\pi} \left(\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s, a_t = a \right).$$

Еще раз повторим, что по своей сути функция ценности действия очень похожа на функцию ценности состояния с той лишь разницей, что мы определяем приведенную выгоду, если начинаем в состоянии s , выбираем действие a и следуем стратегии π .

Вроде бы все логично, и, если бы мы знали все про среду и агента, то достаточно бы было выбирать то действие a , которое максимизирует $q(s, a)$. Конечно, это невозможно, но оказывается, что для функций ценности выполняются рекурсивные отношения.

Лемма 2.2.1 Пусть $v_\pi(s)$ и $q_\pi(s, a)$ – функции ценности состояний и действий, соответственно. Пусть также известна вся информация о среде: известны вероятности всех переходов из состояния s в состояние s' при выполнении действия a

$$\mathcal{P}_{ss'}^a = \mathbf{P}(s_{t+1} = s' | s_t = s, a_t = a)$$

и известны все ожидаемые премии

$$\mathcal{R}_{ss'}^a = \mathbf{E}_\pi(r_{t+1} | s_t = s, a_t = a, s_{t+1} = s').$$

Тогда справедливы следующие соотношения

$$v_\pi(s) = \sum_{a \in A(s)} \pi(a|s) \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v_\pi(s'))$$

и

$$\begin{aligned} q_\pi(s, a) &= \sum_{s' \in S} \mathcal{P}_{ss'}^a \left(\mathcal{R}_{ss'}^a + \gamma \sum_{a' \in A(s')} \pi(a'|s') q_\pi(s', a') \right) = \\ &= \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v_{\pi_i}(s')) \end{aligned}$$

Доказательство. 1. Докажем первое равенство. По определению, используя свойство линейности математического ожидания, получим

$$\begin{aligned} v_\pi(s) &= \mathbf{E}_\pi(G_t | s_t = s) = \mathbf{E}_\pi \left(\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s \right) = \\ &= \mathbf{E}_\pi(r_{t+1} | s_t = s) + \gamma \mathbf{E}_\pi \left(\sum_{k=0}^{\infty} \gamma^k r_{t+k+2} | s_t = s \right). \end{aligned}$$

Рассмотрим пару полученных слагаемых по отдельности. Начнем с первого. Находясь в состоянии s , каждое действие выбирается с вероятностью $\pi(a|s)$,

переход в состояние s' происходит с вероятностью $\mathcal{P}_{ss'}^a$, при этом «выдается» ожидаемая премия $\mathcal{R}_{ss'}^a$. Тогда

$$\mathbb{E}_\pi(r_{t+1}|s_t = s) = \sum_{a \in A(s)} \sum_{s' \in S} \pi(a|s) \mathcal{R}_{ss'}^a \mathcal{P}_{ss'}^a.$$

Аналогично, желая заменить $s_t = s$ на $s_{t+1} = s'$, получим

$$\mathbb{E}_\pi \left(\sum_{k=0}^{\infty} \gamma^k r_{t+k+2} | s_t = s \right) = \sum_{a \in A(s)} \sum_{s' \in S} \pi(a|s) \mathbb{E}_\pi \left(\sum_{k=0}^{\infty} \gamma^k r_{t+k+2} | s_{t+1} = s' \right) \mathcal{P}_{ss'}^a.$$

Складывая и перегруппировывая, получим:

$$v_\pi(s) = \sum_{a \in A(s)} \pi(a|s) \sum_{s' \in S} \mathcal{P}_{ss'}^a \left(\mathcal{R}_{ss'}^a + \gamma \mathbb{E}_\pi \left(\sum_{k=0}^{\infty} \gamma^k r_{t+k+2} | s_{t+1} = s' \right) \right).$$

Так как

$$v_\pi(s') = \mathbb{E}_\pi \left(\sum_{k=0}^{\infty} \gamma^k r_{t+k+2} | s_{t+1} = s' \right),$$

получим

$$v_\pi(s) = \sum_{a \in A(s)} \pi(a|s) \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v_\pi(s')).$$

2. Аналогичным образом доказывается соотношение для $q_\pi(s, a)$. По определению, используя свойство линейности математического ожидания,

$$\begin{aligned} q_\pi(s, a) &= \mathbb{E}_\pi(G_t | s_t = s, a_t = a) = \mathbb{E}_\pi \left(\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s, a_t = a \right) = \\ &= \mathbb{E}_\pi(r_{t+1} | s_t = s, a_t = a) + \gamma \mathbb{E}_\pi \left(\sum_{k=0}^{\infty} \gamma^k r_{t+k+2} | s_t = s, a_t = a \right). \end{aligned}$$

Так как действие a выбрано, то, во-первых,

$$\mathbb{E}_\pi(r_{t+1} | s_t = s, a_t = a) = \sum_{s' \in S} \mathcal{P}_{ss'}^a \mathcal{R}_{ss'}^a,$$

а во-вторых

$$\mathbb{E}_\pi \left(\sum_{k=0}^{\infty} \gamma^k r_{t+k+2} | s_t = s, a_t = a \right) = \sum_{s' \in S} \mathcal{P}_{ss'}^a \mathbb{E}_\pi \left(\sum_{k=0}^{\infty} \gamma^k r_{t+k+2} | s_{t+1} = s', a_t = a \right) =$$

$$= \sum_{s' \in S} \mathcal{P}_{ss'}^a q_\pi(s', a) = \sum_{s' \in S} \mathcal{P}_{ss'}^a \sum_{a' \in A(s')} \pi(a'|s') q_\pi(s', a').$$

В итоге,

$$q_\pi(s, a) = \sum_{s' \in S} \mathcal{P}_{ss'}^a \left(\mathcal{R}_{ss'}^a + \gamma \sum_{a' \in A(s')} \pi(a'|s') q_\pi(s', a') \right) = \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v(s')).$$

□

Ясно, что желая получить функции ценности состояний и действий, мы приходим к системе из $|S|$ уравнений с $|S|$ неизвестными в каждом случае.

Замечание 2.2.2 Полученные уравнения называются уравнениями Беллмана для функций ценности при использовании стратегии π . В случае функций ценности состояний уравнение Беллмана выражает зависимость ценности некоторого состояния от ценностей последующих состояний. В случае функций ценности действий – зависимость ценности пары (состояние, действие) от ценностей последующих таких пар.

Идею (как и технику использования) уравнений можно понять из рисунка [11](#). Пусть нам (откуда-то) известны ценности всех состояний, а в качестве текущего состояния в данном случае рассматривается состояние s_1 , тогда, используя соотношение

$$v_\pi(s) = \sum_{a \in A(s)} \pi(a|s) \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v_\pi(s'))$$

в случае, когда $\gamma = 0.8$, получим

$$\begin{aligned} -2.23 = 0.9 \left(\frac{1}{3} (-10 + 0.8 \cdot 11.45) + \frac{2}{3} (-2 + 0.8 \cdot (-2.23)) \right) + \\ + 0.1 \cdot 1 \cdot (-2 + 0.8 \cdot 6.15), \end{aligned}$$

то есть верное равенство. Конечно, основной возникающий теперь вопрос таков: а как получить ценности состояний? Рассмотрим это на следующем примере.

2.3 Пример

Прежде мы показали как связаны ценность текущего состояния s и следующих состояний s' , в которые может перейти агент. Рассмотрим на примере, как получить ценности всех состояний при помощи уравнений Беллмана, используя конкретную стратегию π . Исходные данные примера представлены




Рис. 11: МППР

на уже знакомом рисунке [12](#). Возьмем в качестве коэффициента дисконтирования $\gamma = 0.8$ и, учитывая, что

$$v_{\pi}(s) = \sum_{a \in A(s)} \pi(a|s) \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v_{\pi}(s')),$$

запишем уравнение Беллмана для состояния «Игра»:

$$\begin{aligned} v_{\pi}(s_1) = & 0.9 \left(\frac{1}{3} (-10 + 0.8v_{\pi}(s_3)) + \frac{2}{3} (-2 + 0.8v_{\pi}(s_1)) \right) + \\ & + 0.1 \cdot 1 \cdot (-2 + 0.8v_{\pi}(s_2)). \end{aligned}$$

Так как во всех состояниях, отличных от s_1 , при совершении конкретного действия переход в следующее состояние детерминирован (осуществляется с вероятностью 1), то внутренняя сумма по s' состоит только лишь из одного слагаемого (умножаемого на 1). Учитывая это наблюдение, аналогичным




Рис. 12: Исходные данные

образом запишем остальные уравнения:

$$v_{\pi}(s_2) = 0.7(-1 + 0.8v_{\pi}(s_1)) + 0.3(7 + 0.8v_{\pi}(s_5)),$$

$$v_{\pi}(s_3) = 0.5(-3 + 0.8v_{\pi}(s_2)) + 0.5(-3 + 0.8v_{\pi}(s_4)),$$

$$v_{\pi}(s_4) = 0.2(5 + 0.8v_{\pi}(s_2)) + 0.8(15 + 0.8v_{\pi}(s_5)),$$

$$v_{\pi}(s_5) = 5 + 0.8v_{\pi}(s_5).$$

Решив эту систему, получим следующие значения ценности состояний (округленные до сотых). Результаты также представлены на рисунке [13](#):

$$\begin{cases} v_{\pi}(s_1) = -2.23 \\ v_{\pi}(s_2) = 6.15 \\ v_{\pi}(s_3) = 11.45 \\ v_{\pi}(s_4) = 29.98 \\ v_{\pi}(s_5) = 25. \end{cases}$$



Рис. 13: Ценности состояний согласно выбранной стратегии

Замечание 2.3.1 Очевидно, что значения ценностей состояний напрямую зависят от выбранной агентом стратегии. При изменении стратегии, вообще говоря, изменятся и ценности состояний. Например, если положить $\pi(a_1|s_1) = 0.5$, $\pi(a_2|s_1) = 0.5$, а остальные параметры оставить прежними, то получим следующие ценности состояний (округленные до сотых)

$$\begin{cases} v_{\pi}(s_1) = 2.59 \\ v_{\pi}(s_2) = 8.85 \\ v_{\pi}(s_3) = 12.71 \\ v_{\pi}(s_4) = 30.42 \\ v_{\pi}(s_5) = 25. \end{cases}$$

Заметим также, что в этом случае ценности всех состояний получились

не меньше, чем соответствующие ценности при использовании предыдущей стратегии. Немного позднее мы обсудим такую ситуацию подробнее.