

Содержание

1	Понятие обучения с подкреплением	2
1.1	Базовые определения и постановка задачи	2
1.2	Компромисс изучение-применение	5
1.3	Постановка задачи о k -руком бандите	6
1.4	Жадная стратегия	10
1.5	ε -жадная стратегия	13
1.6	Softmax-стратегия	17
1.7	Метод UCB (Upper Confidence Bound)	19
1.8	Оптимистичные начальные оценки	22
2	Общая постановка задачи	24
2.1	Взаимосвязь агента и окружающей среды	24
2.2	Функции ценности действий и состояний	32
2.3	Пример	35
2.4	Оценка стратегий	39
2.5	Оптимальные стратегии	46
2.6	SARSA	55
2.7	Q-обучение	60
2.8	Пример	63
2.9	Резюме	65
3	Заключение	65

2.4 Оценка стратегий

В рассмотренном примере мы использовали уравнения Беллмана для нахождения ценности состояний. Для случая пяти состояний сформировать и решить систему линейных уравнений не составляет особого труда. Однако на практике количество возможных состояний агента может быть достаточно велико. Как мы уже отмечали, если количество доступных агенту состояний равно n , то возникает задача решения системы из n уравнений с n неизвестными. Стоит задуматься, а есть ли какой-то способ упростить вычисления? Оказывается есть.

Немного о матричных уравнениях и нормированных пространствах

Оказывается, решение системы уравнений Беллмана можно записать в явном виде. Перепишем систему уравнений

$$v_{\pi}(s) = \sum_{a \in A(s)} \pi(a|s) \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v_{\pi}(s')), \quad s \in S,$$

используя следующие матричные обозначения:

1. Пусть v_{π} – вектор-столбец высоты $|S|$, j -ый элемент которого равен $v_{\pi}(s_j)$, $j \in \{1, 2, \dots, |S|\}$.
2. Пусть r_{π} – вектор-столбец высоты $|S|$, j -ый элемент которого равен $E_{\pi}(r_{t+1}|s_t = s_j)$, $j \in \{1, 2, \dots, |S|\}$.
3. Пусть T_{π} – матрица размера $|S| \times |S|$, с элементами

$$(T_{\pi})_{ij} = P_{\pi}(s_{t+1} = s_j | s_t = s_i) = \sum_{a \in A(s_i)} \pi(a|s_i) \mathcal{P}_{s_i s_j}^a.$$

В таких обозначениях система уравнений Беллмана переписывается, как

$$v_{\pi} = r_{\pi} + \gamma T_{\pi} v_{\pi}.$$

Ясно, что тогда

$$(I - \gamma T_{\pi}) v_{\pi} = r_{\pi} \Rightarrow v_{\pi} = (I - \gamma T_{\pi})^{-1} r_{\pi}.$$

Для исследования написанного выражения, сначала напомним понятие нормированного пространства.

Определение 2.4.1 (Нормированное пространство) Пусть X – линейное пространство. Нормой называется функция $\|\cdot\| : X \rightarrow \mathbb{R}$, удовлетворяющая следующим аксиомам:

1. $\forall x \in X \Rightarrow \|x\| \geq 0$, причем $\|x\| = 0 \Leftrightarrow x = 0$.
2. $\|\lambda x\| = |\lambda| \|x\|$, $\lambda \in \mathbb{R}$, $x \in X$.
3. $\|x + y\| \leq \|x\| + \|y\|$, $x, y \in X$.

Замечание 2.4.1 Понятно, что норма в общем случае обобщает понятие длины. Если $X = \mathbb{R}$, то можно положить $\|x\| = |x|$. Если, например, $X = \mathbb{R}^n$, то в качестве нормы $x = (x_1, x_2, \dots, x_n) \in \mathbb{R}^n$ можно рассмотреть знакомую нам длину вектора:

$$\|x\| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}.$$

Замечание 2.4.2 В $\mathbb{R}^n$ можно рассмотреть и другие нормы, например

$$\|x\|_p = \sqrt[p]{|x_1|^p + |x_2|^p + \dots + |x_n|^p}, \quad p \in \mathbb{N}.$$

Знакомая нам длина вектора – частный случай написанной нормы при $p = 2$. Мы будем пользоваться в дальнейшем нормой при $p = +\infty$:

$$\|x\|_\infty = \max_{i \in \{1, \dots, n\}} |x_i|.$$

Теперь перейдем к понятию нормы оператора.

Определение 2.4.2 Пусть X – линейное нормированное пространство и $A : X \rightarrow X$ – линейный оператор. Нормой оператора A называется величина

$$\|A\| = \sup_{x: \|x\|=1} \|Ax\|.$$

Итак, норма оператора в некотором смысле – это число, которое показывает максимальное значение «растяжения» вектора единичной длины под действием оператора A . Заметим, что в конечномерном пространстве норма оператора всегда конечна.

Замечание 2.4.3 Отметим, что из определения нормы сразу следует неравенство

$$\|Ax\| \leq \|A\| \|x\|, \quad \forall x \in X.$$

Замечание 2.4.4 Хорошо известно, что всякий линейный оператор $A : X \rightarrow X$ может быть отождествлен с его матрицей (в случае, когда в X фиксирован некоторый базис). При этом сумме и произведению операторов отвечает сумма и произведение соответствующих матриц, а обратному оператору – обратная матрица. В итоге, обратимость оператора равносильна обратимости его матрицы в некотором базисе.

Пример 2.4.1 Найдем норму оператора $A : \mathbb{R}^n \rightarrow \mathbb{R}^n$ с нормой $\|x\|_\infty$. Пусть в фиксированном базисе оператору сопоставлена матрица A с элементами a_{ij} , $i, j \in \{1, 2, \dots, n\}$. Тогда,

$$\|Ax\|_\infty = \max_{i \in \{1, \dots, n\}} \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \max_{i \in \{1, \dots, n\}} \sum_{j=1}^n |a_{ij}| \|x\|_\infty.$$

Итого, при $x \neq 0$, обозначив $y = \frac{x}{\|x\|_\infty}$

$$\|Ay\| \leq \max_{i \in \{1, \dots, n\}} \sum_{j=1}^n |a_{ij}|, \quad \|y\|_\infty = 1.$$

Если мы докажем, что написанная оценка достигается, то мы докажем, что

$$\|A\| = \max_{i \in \{1, \dots, n\}} \sum_{j=1}^n |a_{ij}|.$$

Пусть хотя бы один элемент матрицы не равен нулю (иначе его норма равна 0 и равенство, очевидно, достигается). Тогда пусть

$$i_0 = \arg \max_{i \in \{1, \dots, n\}} \sum_{j=1}^n |a_{ij}|$$

– какое-то i , на котором достигается максимум. Тогда в качестве x возьмем вектор $x = (\text{sign } a_{i_0 1}, \text{sign } a_{i_0 2}, \dots, \text{sign } a_{i_0 n})$. Ясно, что $\|x\|_\infty = 1$ и

$$Ax = \sum_{j=1}^n a_{i_0 j} \text{sign } a_{i_0 j} = \sum_{j=1}^n |a_{i_0 j}| = \max_{i \in \{1, \dots, n\}} \sum_{j=1}^n |a_{ij}|.$$

Лемма 2.4.1 (Об обратимости оператора) Для того чтобы линейный оператор $A : X \rightarrow X$, X – нормированное пространство с нормой $\|\cdot\|$, был обратим, необходимо и достаточно, чтобы нашлось такое $m > 0$, что

$$\forall x \in X \Rightarrow \|Ax\| \geq m\|x\|.$$

Доказательство. Докажем достаточность. Написанное неравенство означает, что при $x_1 \neq 0 \Rightarrow Ax_1 \neq 0$. В случае линейности оператора это и означает обратимость.

Докажем необходимость. Пусть оператор обратим, тогда $y = Ax$, $x = A^{-1}y$ и

$$\|A^{-1}y\| \leq \|A^{-1}\|\|y\| \Rightarrow \|x\| \leq \|A^{-1}\|\|Ax\| \Rightarrow \|Ax\| \geq \|A^{-1}\|^{-1}\|x\|$$

и $m = \|A^{-1}\|^{-1}$. □

Лемма 2.4.2 (О существовании решения системы) Пусть $\gamma \in (0, 1)$. Матрица $(I - \gamma T_\pi)$ обратима, а значит решение системы уравнений Беллмана существует и единственно, причем

$$v_\pi = (I - \gamma T_\pi)^{-1} r_\pi.$$

Доказательство. Обратимость матрицы равносильна обратимости оператора, заданного в фиксированном базисе матрицей $(I - \gamma T_\pi)$. Так как $\|I\| = 1$ и $\|T_\pi\| = 1$ (так как рассматривается пространство $R^{|S|}$ с нормой $\|x\|_\infty$), то

$$\|(I - \gamma T_\pi)x\| \geq \|Ix\| - \gamma\|T_\pi x\| \geq (1 - \gamma)\|x\|.$$

Значит, оператор обратим, и лемма доказана. □

Введем следующее важное определение.

Определение 2.4.3 Пусть $A : X \rightarrow X$ – линейный оператор, X – нормированное пространство. Оператор A называется сжатием, если $\exists \alpha \in (0, 1)$, что

$$\|Ax - Ay\| \leq \alpha\|x - y\|$$

По сути своей сжатие уменьшает расстояние между образами.

Определение 2.4.4 Пусть $A : X \rightarrow X$ – линейный оператор. Тогда точка $x^* \in X$, для которой

$$Ax^* = x^*$$

называется неподвижной точкой оператора A .

Неподвижные точки оператора – точки, которые переходят сами в себя под действием оператора.

Теорема 2.4.1 (Простейший метод сжимающих отображений)

Пусть $A : \mathbb{R}^n \rightarrow \mathbb{R}^n$ – линейный оператор, являющийся сжатием с параметром α , $\|\cdot\|$ – произвольная норма в $\mathbb{R}^n$. Тогда у оператора A существует единственная неподвижная точка x^* , причем последовательность

$$x_{k+1} = Ax_k, \quad x_0 \in \mathbb{R}^n$$

сходится к x^* при $k \rightarrow +\infty$. Кроме того,

$$\|x^* - x_k\| \leq \frac{\alpha^k}{1 - \alpha} \|x_1 - x_0\|.$$

Доказательство. Покажем, что последовательность x_k фундаментальна. Из этого будет следовать ее сходимости (вне зависимости от введенной нормы). Используя неравенство треугольника, получим

$$\|x_{k+p} - x_k\| \leq \|x_{k+p} - x_{k+p-1}\| + \|x_{k+p-1} - x_{k+p-2}\| + \dots + \|x_{k+1} - x_k\|.$$

Воспользуемся определением последовательности x_k , тогда

$$\begin{aligned} \|x_{k+p} - x_k\| &\leq \|Ax_{k+p-1} - Ax_{k+p-2}\| + \dots + \|Ax_k - Ax_{k-1}\| \leq \\ &(\alpha^{k+p-1} + \dots + \alpha^k) \|x_1 - x_0\| = \frac{\alpha^k(1 - \alpha^p)}{1 - \alpha} \|x_1 - x_0\| \leq \frac{\alpha^k}{1 - \alpha} \|x_1 - x_0\|, \end{aligned}$$

что и доказывает фундаментальность. Тем самым, последовательность сходится. Пусть $p \rightarrow +\infty$, тогда

$$\|x^* - x_k\| \leq \frac{\alpha^k}{1 - \alpha} \|x_1 - x_0\|.$$

Докажем единственность. Пусть x^*, y^* – две неподвижные точки. Тогда

$$\|x^* - y^*\| = \|Ax^* - Ay^*\| \leq \alpha \|x^* - y^*\|.$$

Отсюда, $\|x^* - y^*\| = 0$ и $x^* = y^*$. □

Итеративная оценка стратегий

Итак, мы готовы сформулировать теорему об итеративной оценке стратегии.

Теорема 2.4.2 (Об итеративной оценке стратегий) Пусть $v_\pi(s)$ – функция ценности состояния, $s \in S$. Пусть так же $v_0(s) \in \mathbb{R}$ – произвольное число, если состояние s не является терминальным, и $v_0(s) = 0$ иначе. Тогда последовательность

$$v_{k+1}(s) = \sum_{a \in A(s)} \pi(a|s) \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v_k(s'))$$

сходится к $v_\pi(s)$ при $k \rightarrow +\infty$.

Доказательство. Рассмотрим так называемый оператор Беллмана

$$Bv = r_\pi + \gamma T_\pi v.$$

Покажем, что этот оператор является сжатием при рассмотрении нормы $\|\cdot\|_\infty$. Так как в этом случае $\|T_\pi\| = 1$, то

$$\|Bv - Bv'\|_\infty = \|\gamma T_\pi(v - v')\| \leq \gamma \|v - v'\|.$$

Осталось применить доказанный метод сжимающих отображений. $\square$

Замечание 2.4.5 Можно произвести оценку погрешности при замене истинной ценности состояния ее приближением.

$$|v_\pi(s) - v_k(s)| \leq \frac{\gamma^k}{1 - \gamma} \max_{s \in S} |v_1(s) - v_0(s)|.$$

Получается, что для оценки ценности состояний при использовании некоторой стратегии, можно использовать следующий алгоритм:

Алгоритм 1. Итеративная оценка стратегии

- 1: Выбор оцениваемой стратегии
 - 2: Инициализировать $v_0(s) = 0$ для всех $s \in S$
 - 3: Инициализировать $k = 0$
 - 4: **Выполнять**
 - 5: $\Delta \leftarrow 0$
 - 6: **Для** $s \in S$ **Выполнять**
 - 7: $v^* \leftarrow v_k(s)$
 - 8: $v_{k+1}(s) \leftarrow \sum_{a \in A(s)} \pi(a|s) \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v_k(s'))$
 - 9: $\Delta \leftarrow \max(\Delta, |v^* - v_{k+1}(s)|)$
 - 10: **Конец цикла**
 - 11: $k \leftarrow k + 1$
 - 12: **Повторять пока** $\Delta < \theta$ (малое положительное число)
 - 13: **Возвратить** v_k
-

Применим описанный алгоритм для уже знакомого примера. Схема МППР изображена на рисунке [16](#).

На первом этапе все значения ценностей состояний были приняты равными нулю. Далее, на каждом шаге значения ценностей обновлялись в соответствии с ранее полученными уравнениями Беллмана:

$$\begin{aligned} v_{k+1}(s_1) &= 0.9 \left(\frac{1}{3} (-10 + 0.8v_k(s_3)) + \frac{2}{3} (-2 + 0.8v_k(s_1)) \right) + \\ &\quad + 0.1 \cdot 1 \cdot (-2 + 0.8v_k(s_2)). \\ v_{k+1}(s_2) &= 0.7(-1 + 0.8v_k(s_1)) + 0.3(7 + 0.8v_k(s_5)) \end{aligned}$$




Рис. 14: Исходные данные

$$v_{k+1}(s_3) = 0.5(-3 + 0.8v_k(s_2)) + 0.5(-3 + 0.8v_k(s_4))$$

$$v_{k+1}(s_4) = 0.2(5 + 0.8v_k(s_2)) + 0.8(15 + 0.8v_k(s_5))$$

$$v_{k+1}(s_5) = 5 + 0.8v_k(s_5)$$

Результаты вычислений (округленные до сотых) представлены в таблице

Шаг	$v_k(s_1)$	$v_k(s_2)$	$v_k(s_3)$	$v_k(s_4)$	$v_k(s_5)$
0	0	0	0	0	0
1	-4.4	1.4	-3	13	5
2	-7.12	0.14	2.76	16.42	9
3	-7.14	-0.43	3.62	18.78	12.2
...	...	...	...	...	...
36	-2.24	6.14	11.45	29.98	24.99
37	-2.23	6.15	11.45	29.98	24.99
38	-2.23	6.15	11.45	29.98	24.99
39	-2.23	6.15	11.45	29.98	25

Заметим, что для получения требуемой точности (совпадение в сотых) понадобилось достаточно большое количество итераций. Погрешность составляет меньше, чем

$$13 \cdot \frac{0.8^{39}}{1 - 0.8} \approx 0.011.$$

2.5 Оптимальные стратегии

С точки зрения обучения с подкреплением, нам интересны не столько состояния, сколько стратегии, которые обеспечивают максимальную приведенную выгоду. Находя решение уравнения Беллмана для каждой стратегии, можно выбрать наилучшую или так называемую оптимальную стратегию. Что означают эти слова? Сначала введем определения.

Определение 2.5.1 Функция

$$v^*(s) = \max_{\pi} v_{\pi}(s), \quad \forall s \in S,$$

называется оптимальной функцией ценности состояний.

Определение 2.5.2 Функция

$$q^*(s, a) = \max_{\pi} q_{\pi}(s, a), \quad \forall s \in S, \forall a \in A(s),$$

называется оптимальной функцией ценности действий.

Итак, введенные функции показывают, какой максимальной может быть ценность состояния и (или) действия.

Замечание 2.5.1 Покажем, что максимумы, написанные выше, в случае финитного марковского процесса принятия решений, существуют. Например, почему $v^*(s)$ – корректно определенная функция? Согласно уравнению Беллмана,

$$\begin{aligned} v_{\pi}(s) &= \sum_{a \in A(s)} \pi(a|s) \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v_{\pi}(s')) \leq \\ &\leq \sum_{a \in A(s)} \pi(a|s) \max_{a \in A(s)} \left(\sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v_{\pi}(s')) \right) = \\ &= \max_{a \in A(s)} \left(\sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v_{\pi}(s')) \right) = \max_{a \in A(s)} q_{\pi}(s, a). \end{aligned}$$

Так как множество $A(s)$ конечно, то ясно, что стратегия, на которой достигается полученное справа выражение, такова (в случае, когда максимум достигается на одном действии):

$$\pi(a|s) = \begin{cases} 1, & a = \arg \max_{a \in A(s)} q_\pi(s, a) \\ 0, & \text{иначе} \end{cases}.$$

Если максимум достигается на нескольких действиях, то можно выбрать любое из них. Итак, мы оценили нашу функцию сверху и нашли стратегию, на которой эта оценка достигается. Значит, это и есть искомый максимум.

Те же самые рассуждения полезно провести в терминах стратегий.

Определение 2.5.3 Говорят, что стратегия π не хуже, чем стратегия π' , и пишут

$$\pi \geq \pi',$$

если для всех $s \in S$

$$v_\pi(s) \geq v_{\pi'}(s).$$

Замечание 2.5.2 Часто говорят, что введенное отношение $\geq$ индуцирует (или вводит) частичный порядок на множестве всех стратегий π . Обратите внимание, что может случиться так, что какие-то две стратегии π_1 и π_2 не сравнимы. Это значит, что найдутся $s_1, s_2 \in S$, что

$$v_{\pi_1}(s_1) \leq v_{\pi_2}(s_1),$$

но

$$v_{\pi_1}(s_2) \geq v_{\pi_2}(s_2).$$

Пример 2.5.1 Если в уже рассмотренном примере вместо оригинальной стратегии рисунок (15.а)) использовать стратегию π' , где $\pi'(a_1|s_1) = 1, \pi'(a_2|s_1) = 0, \pi'(a_4|s_4) = 1, \pi'(a_2|s_4) = 0$ (рисунок (15.б)), то получим следующие ценности состояний:

Стратегия	$v(s_1)$	$v(s_2)$	$v(s_3)$	$v(s_4)$	$v(s_5)$
π	-2.23	6.15	11.45	29.98	25
π'	-2.32	6.1	13.44	35	25

Можно заметить, что для состояний s_1 и s_2 более высокие значения ценности получаются при использовании стратегии π , а для s_3 и s_4 ситуация обратная.




Рис. 15: Пример несравнимых стратегий.

Конечно, хочется найти такую стратегию, которая не хуже всех других.

Определение 2.5.4 Стратегия π^* называется оптимальной, если для любой стратегии π выполнено неравенство

$$\pi^* \geq \pi.$$

Замечание 2.5.3 Конечно, введенное определение влечет сразу много вопросов: всегда ли существует оптимальная стратегия, и будет ли оптимальная стратегия единственной? Оказывается, что в общем случае ответ на оба вопроса: «Нет». Мы вернемся к этому чуть позже.

В то же время, имея оптимальную стратегию π^* , логично ввести в рассмотрение и функции $v_{\pi^*}(s)$ и $q_{\pi^*}(s, a)$, которые являются кандидатами на роль оптимальной функции ценности состояний и действий, соответственно. Давайте выясним их связь. Во-первых установим, что функции $v_{\pi^*}(s)$ и $q_{\pi^*}(s, a)$ в случае, когда оптимальная стратегия существует, определены корректно (на разных оптимальных стратегиях они дают одно и то же значение).

Лемма 2.5.1 Для любых двух оптимальных стратегий π_1^* и π_2^*

$$v_{\pi_1^*} \equiv v_{\pi_2^*} \text{ и } q_{\pi_1^*} \equiv q_{\pi_2^*}.$$

Доказательство. Докажем, например, первое тождество. Так как π_1^* – оптимальная стратегия, то, согласно определению,

$$v_{\pi_1^*}(s) \geq v_{\pi}(s), \quad \forall s \in S,$$

в частности, когда $\pi = \pi_2^*$, откуда $v_{\pi_1^*}(s) \geq v_{\pi_2^*}(s)$. Меняя π_1^* и π_2^* местами, получаем неравенство $v_{\pi_2^*}(s) \geq v_{\pi_1^*}(s)$, что и завершает доказательство. $\square$

Ответим теперь на вопрос: а всегда ли существует оптимальная стратегия? Оказывается, в предположении финитности марковского процесса принятия решений, да. Кроме того, справедлива следующая (достаточно ожидаемая) теорема.

Теорема 2.5.1 *Пусть марковский процесс принятия решений является финитным. Тогда*

1. *Существует оптимальная стратегия π^* .*
2. *Для любой оптимальной стратегии $v_{\pi^*} \equiv v^*$.*
3. *Для любой оптимальной стратегии $q_{\pi^*} \equiv q^*$.*

Итак, оказывается, что оптимальные функции ценности состояний и действий – это соответствующие функции ценности состояний и действий в случае, когда используется оптимальная стратегия.

Доказательство. Доказательство следует из того, что было показано ранее. На роль оптимальной стратегии π^* подходит, например, такая (если максимум достигается лишь на одном действии):

$$\pi(a|s) = \begin{cases} 1, & a = \arg \max_{a \in A(s)} q_{\pi}(a) \\ 0, & \text{иначе} \end{cases}.$$

Если максимум достигается на нескольких действиях, то можно выбирать любое из них. Дальнейшие рассуждения очевидны. $\square$

Аналогично тому, как были найдены уравнения Беллмана для $v_{\pi}(s)$ и $q_{\pi}(s, a)$, найдем их и для $v^*(s)$ и $q^*(s, a)$.

Лемма 2.5.2 *Пусть $v^*(s)$ и $q^*(s, a)$ – оптимальные функции ценности состояний и действий соответственно, тогда имеют место следующие соотношения.*

$$v^*(s) = \max_{a \in A(s)} \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v^*(s')),$$

$$q^*(s, a) = \sum_{s' \in S} \mathcal{P}_{ss'}^a \left(\mathcal{R}_{ss'}^a + \gamma \max_{a' \in A(s')} q^*(s', a') \right).$$

Доказательство. Как мы выяснили, оптимальные функции ценности – это функции ценности на оптимальной стратегии π^* , то есть, если максимум достигается на одном действии, на стратегии

$$\pi(a|s) = \begin{cases} 1, & a = \arg \max_{a \in A(s)} q_{\pi}(a) \\ 0, & \text{иначе} \end{cases}.$$

Так как в общем случае

$$v_\pi(s) = \sum_{a \in A(s)} \pi(a|s) \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{P}_{ss'}^a + \gamma v_\pi(s')),$$

то для оптимальной стратегии π^*

$$v^*(s) = \max_{a \in A(s)} \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v^*(s')).$$

Аналогично доказывается второе соотношение. $\square$

Замечание 2.5.4 Важно понимать, что знание оптимальной функции ценности состояний сразу дает нам и оптимальную стратегию: нужно переходить в то состояние, чья ценность больше!

Замечание 2.5.5 В качестве замечания отметим, что полученные уравнения называют уравнениями оптимальности Беллмана относительно ценности состояний и действий, соответственно. В отличие от уравнений Беллмана, полученная система уже не является системой линейных алгебраических уравнений, поэтому ее решение – отдельная задача.

Оказывается, рассмотренный ранее итерационный подход помогает и в этой ситуации.

Теорема 2.5.2 Пусть $v^*(s)$ – оптимальная функция ценности состояния, $s \in S$. Пусть так же $v_0(s) \in \mathbb{R}$ – произвольное число, если состояние s не является терминальным, и $v_0(s) = 0$ иначе. Тогда последовательность

$$v_{k+1}(s) = \max_{a \in A(s)} \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v_k(s'))$$

сходится к $v^*(s)$ при $k \rightarrow +\infty$.

Доказательство. Рассмотрим оптимальный оператор Беллмана B^* , действующий по правилу

$$B^*v = \max_{a \in A} \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v(s')),$$

где

$$v = (v(s_1), v(s_2), \dots, v(s_{|S|}))^T.$$

Рассмотрим B^*v и B^*v' . В силу финитности ММПР, найдутся a и a' (не обязательно различные), что

$$B^*v = \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v(s')),$$

$$B^*v' = \sum_{s' \in S} \mathcal{P}_{ss'}^{a'}(R_{ss'}^{a'} + \gamma v'(s')).$$

Кроме того, $B^*v' \geq \sum_{s' \in S} \mathcal{P}_{ss'}^a(R_{ss'}^a + \gamma v'(s'))$, откуда

$$\begin{aligned} B^*v - B^*v' &\leq \sum_{s' \in S} \mathcal{P}_{ss'}^a(R_{ss'}^a + \gamma v(s')) - \sum_{s' \in S} \mathcal{P}_{ss'}^a(R_{ss'}^a + \gamma v'(s')) = \\ &= \gamma \sum_{s' \in S} \mathcal{P}_{ss'}^a(v(s') - v'(s')) \leq \gamma \|v - v'\|_\infty. \end{aligned}$$

Меняя v и v' местами, получим, что

$$|B^*v - B^*v'| \leq \gamma \|v - v'\|_\infty \Rightarrow \|B^*v - B^*v'\|_\infty \leq \gamma \|v - v'\|_\infty.$$

Осталось воспользоваться простейшим методом сжимающих отображений. $\square$

Аналогично сделанному ранее, можно сформулировать алгоритм итеративного поиска оптимальных функций состояний.

Алгоритм 2. Итеративная оценка оптимальной стратегии

- 1: Выбор оцениваемой стратегии
 - 2: Инициализировать $v_0(s) = 0$ для всех $s \in S$
 - 3: Инициализировать $k = 0$
 - 4: **Выполнять**
 - 5: $\Delta \leftarrow 0$
 - 6: **Для** $s \in S$ **Выполнять**
 - 7: $v^* \leftarrow v_k(s)$
 - 8: $v_{k+1}(s) \leftarrow \max_{a \in A(s)} \sum_{s' \in S} \mathcal{P}_{ss'}^a(R_{ss'}^a + \gamma v_k(s'))$
 - 9: $\Delta \leftarrow \max(\Delta, |v^* - v_{k+1}(s)|)$
 - 10: **Конец цикла**
 - 11: $k \leftarrow k + 1$
 - 12: **Повторять пока** $\Delta < \theta$ (малое положительное число)
 - 13: **Возвратить** v_k
-

Замечание 2.5.6 Аналогично тому, как было сделано ранее, можно оценить погрешность между истинным и приближенным значением оптимальной стратегии на каждом шаге алгоритма.

Вернемся к уже знакомому примеру одного дня из жизни ребенка (рисунок [16](#)) и выясним, какие же действия стоит предпринимать агенту, чтобы максимизировать приведенный выигрыш.

Значения ценностей состояний для случая использования оптимальной стратегии представлены на рисунке [17](#).



Рис. 16: Исходные данные

Убедимся в том, что полученные значения действительно соответствуют оптимальной стратегии, а именно проверим, что для каждого состояния выполняется равенство

$$v^*(s) = \max_{a \in A(s)} \sum_{s' \in S} \mathcal{P}_{ss'}^a (\mathcal{R}_{ss'}^a + \gamma v^*(s')).$$

Для $v^*(s_1)$ имеем

$$19.6 = \max \left\{ \left(\frac{1}{3}(-10 + 0.8 \cdot 25) + \frac{2}{3}(-2 + 0.8 \cdot 19.6) \right), \right. \\ \left. (-2 + 0.8 \cdot 27) \right\},$$

то есть

$$19.6 = \max\{12.45, 19.6\},$$




Рис. 17: Ценности состояний при использовании оптимальной стратегии

что верно. Аналогично для $v^*(s_2)$:

$$27 = \max\{(-1 + 0.8 \cdot 19.6), (7 + 0.8 \cdot 25)\} = \max\{14.68, 27\},$$

что тоже верно, и так далее.

Заметим, что зная значения оптимальной функции ценности состояний, стратегия формируется достаточно очевидным образом: нужно просто переходить в состояние с максимальным значением ценности (рисунок 18).

Смотрите, теперь наша стратегия стала полностью детерминированной: в каждый момент времени агент точно знает какое действие следует предпринять. Например, находясь в состоянии «Игра», нужно поесть и отправляться спать, а если заплакал – отправиться на прогулку, поесть а затем уснуть.

Важным остается вопрос, а как же получить требуемые значения ценности состояний. Для получения точных значений можно решить систему уравнений оптимальности Беллмана, которая для нашего пример будет вы-



Рис. 18: Оптимальная стратегия

глядеть следующим образом:

$$v^*(s_1) = \max \left\{ \left(\frac{1}{3}(-10 + 0.8v^*(s_3)) + \frac{2}{3}(-2 + 0.8v^*(s_1)) \right), \right. \\ \left. (-2 + 0.8v^*(s_2)) \right\},$$

$$v^*(s_2) = \max\{(-1 + 0.8v^*(s_1)), (7 + 0.8v^*(s_5))\}$$

$$v^*(s_3) = \max\{(-3 + 0.8v^*(s_2)), (-3 + 0.8v^*(s_4))\}$$

$$v^*(s_4) = \max\{(5 + 0.8v^*(s_2)), (15 + 0.8v^*(s_5))\}$$

$$v^*(s_5) = 5 + 0.8v^*(s_5)$$

Очевидно, что эта система уже не является линейной, а значит ее решение отыскать не так просто. Тут и пригодится ранее рассмотренный итерационный метод. Положим на первом шаге все значения ценностей равными нулю. Результаты вычислений (округленные до сотых) представлены в таблице

Шаг	$v_k(s_1)$	$v_k(s_2)$	$v_k(s_3)$	$v_k(s_4)$	$v_k(s_5)$
0	0	0	0	0	0
1	-2	7	-3	15	5
2	3.6	11	9	19	9
3	6.8	14.2	12.2	22.2	12.2
.....					
38	19.59	26.99	24.99	34.99	24.99
39	19.6	27	25	35	25

Отметим, что для достижения приемлемого уровня точности (совпадение в сотых) в нашем случае потребовалось порядка сорока итераций, что в данном случае вполне оправдано.