

Содержание

1 Введение	2
2 Энтропия	4
2.1 Немного о степени неопределенности	4
2.2 Энтропия Шеннона и проверка ожидаемых свойств	6
3 Условная энтропия	11
3.1 Наводящие соображения	11
3.2 Определение условной энтропии	12
3.3 Пример на вычисление условной энтропии	17
3.4 Энтропия и прирост информации	19
3.5 Вычисление прироста информации на конкретном примере	21
4 Деревья принятия решений	23
4.1 Немного о самих деревьях	23
4.2 Алгоритм построения дерева и пример с кошками	25
4.3 Бинарное дерево решений	28
4.4 Типы признаков и их группировка	30
4.4.1 Алгоритм построения бинарного дерева решений и при-	
мер с кошками	32
4.4.2 Синтетический пример	34
5 Неопределенность Джини	37
5.1 Определение и свойства	37
5.2 Небольшое сравнение прироста Джини и энтропии	44
5.3 Прирост Джини на данных	45
6 Деревья принятия решений на реальном примере	46
7 Заключение	49



—

—

6 Деревья принятия решений на реальном примере

Одним из примеров применения деревьев принятия решений являются системы скоринга, используемые банками для оценки клиентов. Например, некий банк имеет клиентскую базу, и хочет понять, какие клиенты согласятся на оформление потребительского кредита в будущем, а какие нет.

Рассмотрим данные (рисунок 13) о текущих клиентах банка¹ – всего 12 предикторов, среди которых: возраст, опыт работы, доход, семейное положение, образование и проч., и отклик – *PersonalLoan*, принимающий значений 0, если клиент отказался оформить потребительский кредит, и 1 – если согласился. Исходный объем данных содержит 5000 объектов. Для дальнейшей оценки качества модели, мы его разделили на тренировочные и тестовые данные в отношении 70% на 30%. Таким образом, обучение модели осуществляется на 3500 объектах (3158 из которых относятся к классу 0 – клиенты отказавшиеся оформлять потребительский кредит, остальные к классу 1 –




Рис. 13: Пример тренировочных данных.

согласились). Отметим, что все предикторы принимают числовые значения, то есть являются некатегориальными. Будем строить бинарное дерево решений. В качестве критерия разделения будем использовать критерий $X_i \leq C$, где C – пороговый параметр из диапазона значений, принимаемых предиктором X_i . Так, на первом уровне, самым информативным является разделение по доходу (предиктор *Income*) с пороговым значением 92.5 тысячи долларов в год. Такое разделение приводит к достаточно информативному множеству S_{11} с близкой к нулю энтропией, второе же множество – S_{12} обладает высокой степенью неопределенности.

Теперь построим второй уровень дерева. Для S_{11} самым информативным будет разделение по предиктору *CCAvg* – расходы по кредитным картам в

¹<https://www.kaggle.com/itsmesunil/bank-loan-modelling>

месяц. Для $S_{12} - Education$ – уровень образования (он принимает значения 1 – для студентов, 2 – для выпускников и 3 – для имеющих профессиональное образование (степень)). В результате, уже на втором уровне мы получаем подмножество из 2393 клиентов, которые отнесены к классу 0 (левый блок с нулевой энтропией) – это клиенты, которые не соглашались на оформление потребительского кредита, имели доход не более 92.5 тысяч долларов в год и незначительные расходы по кредитной карте – не более 2.95 тысячи долларов в месяц.

Третий уровень дерева построен для оставшихся множеств с ненулевой энтропией – множеств S_{22}, S_{23}, S_{24} . На этом уровне тоже получаем множество с нулевой энтропией (правый нижний блок на рисунке 14). На этот раз блок отвечает клиентам, согласившимся оформить потребительский кредит. Что это за клиенты, согласно построенному дереву? Это клиенты с высоким доходом, более 116.5 тысяч долларов в год и либо выпускники, либо имеющие дополнительный уровень образования (степень).

В остальных подмножествах присутствуют разные клиенты, и мы можем либо продолжить построение дерева, либо закончить на трех уровнях. В таком случае класс назначается, как обычно, исходя из «большинства».

На основании классификации тестовых данных, по построенному дереву может быть составлена матрица ошибок: Полученные результаты свидетель-

Матрица ошибок		Исходный класс	
		+	–
Прогноз	+	TP=108	FP=7
	–	FN=30	TN=1355

ствуют о высокой точности модели

$$Precision = \frac{TP}{TP + FP} = \frac{108}{108 + 7} \approx 0.9391,$$

а также полноте

$$Recall = \frac{TP}{TP + FN} = \frac{108}{108 + 30} \approx 0.7826.$$

Обучение на аналогичных данных, но с использованием неопределенности Джини, приводит к результату, отображенному на рисунке 15. Можно заметить, что многие критерии схожи с ранее построенным деревом. Кроме того, классификация тестовых данных дает тоже схожий результат: Точность и полнота немного, но повысились:

$$Precision = \frac{TP}{TP + FP} = \frac{113}{113 + 4} \approx 0.9658,$$

$$Recall = \frac{TP}{TP + FN} = \frac{113}{113 + 25} \approx 0.8188.$$

Матрица ошибок		Исходный класс	
		+	–
Прогноз	+	TP=113	FP=4
	–	FN=25	TN=1358

7 Заключение

Итак, в этой лекции мы осветили еще один подход к классификации – деревья принятия решений, основная сфера применения которых – поддержка процессов принятия управленческих решений. Метод не наделен такими тонкостями, как подбор гиперпараметров модели, и позволяет быстро обучить модель. Выбор той или иной меры неопределенности существенно не сказывается на результатах классификации, а ограничения по глубине дерева или количеству элементов в каждом узле дерева являются эвристическими подходами, т.е. не гарантируют лучшего результата или вообще работают только в каких-то частных случаях. Кроме того, обоснованных рекомендаций по тому, какой метод лучше работает, в настоящее время не существует, и окончательное решение остается на откуп исследователю.