


Содержание

1 Введение	2
2 Энтропия	4
2.1 Немного о степени неопределенности	4
2.2 Энтропия Шеннона и проверка ожидаемых свойств	6
3 Условная энтропия	11
3.1 Наводящие соображения	11
3.2 Определение условной энтропии	12
3.3 Пример на вычисление условной энтропии	17
3.4 Энтропия и прирост информации	19
3.5 Вычисление прироста информации на конкретном примере	21
4 Деревья принятия решений	23
4.1 Немного о самих деревьях	23
4.2 Алгоритм построения дерева и пример с кошками	25
4.3 Бинарное дерево решений	28
4.4 Типы признаков и их группировка	30
4.4.1 Алгоритм построения бинарного дерева решений и при-	
мер с кошками	32
4.4.2 Синтетический пример	34
5 Неопределенность Джини	37
5.1 Определение и свойства	37
5.2 Небольшое сравнение прироста Джини и энтропии	44
5.3 Прирост Джини на данных	45
6 Деревья принятия решений на реальном примере	46
7 Заключение	49



5 Неопределенность Джини

5.1 Определение и свойства

При построении деревьев принятия решений используют и другие критерии информативности. Среди них можно выделить особо так называемую неопределенность Джини (Gini impurity), которая является мерой неправильной классификации.

Что значит неправильная классификация? Для демонстрации происходящего, снова вернемся к эксперименту с опросом друзей. В нем мы получили, что из 14 опрошенных друзей 9 согласились пойти играть в футбол, а 5 нет. Тогда эксперимент задается следующей таблицей



Рис. 8: Классификация на основе дерева решений (итоговое разделение).

Ω	Да	Нет
P	$\frac{9}{14}$	$\frac{5}{14}$

Предположим, что мы берем случайного друга. Какова вероятность события, что мы его неверно классифицируем? Это событие распадается на два: он либо хочет играть в футбол, а мы его отнесем к группе, которая не хочет, либо наоборот. Ясно, что вероятность такого события может быть вычислена, как

$$P(\text{друг неверно классифицирован}) = \frac{9}{14} \cdot \frac{5}{14} + \frac{5}{14} \cdot \frac{9}{14} = \frac{90}{196}.$$

Эта величина и есть неопределенность Джини или мера неправильной классификации. Итак, введем формальное определение.

Определение 5.1.1 Пусть эксперимент Ω описывается таблицей



Рис. 9: Классификация новых объектов на основе обученной модели.


$$\begin{array}{c|c|c|c|c} \Omega & \omega_1 & \omega_2 & \dots & \omega_n \\ \hline P & P_1 & P_2 & \dots & P_n \end{array}.$$

Неопределенностью Джини $G(\Omega)$ эксперимента Ω называется величина

$$G(\Omega) = \sum_{i=1}^n P_i(1 - P_i).$$

Замечание 5.1.1 Полезно заметить, что выражения для неопределенности Джини эквивалентным образом может быть переписано и вот так:

$$G(\Omega) = 1 - \sum_{i=1}^n P_i^2.$$



data_tree_6.png

Рис. 10: Классификация на основе дерева решений (6 уровней).

Это представление легко получается из следующих выкладок:

$$G(\Omega) = \sum_{i=1}^n P_i(1 - P_i) = \sum_{i=1}^n (P_i - P_i^2) = \sum_{i=1}^n P_i - \sum_{i=1}^n P_i^2 = 1 - \sum_{i=1}^n P_i^2.$$

Как же связаны неопределенность Джини и энтропия? Оказывается, неопределенность Джини обладает схожими свойствами, что и энтропия.

Теорема 5.1.1 Пусть рассматривается эксперимент Ω . Тогда

$$G(\Omega) = 0 \Leftrightarrow H(\Omega) = 0.$$

Так как энтропия равна нулю тогда и только тогда, когда у эксперимента ровно один исход имеет вероятность 1 (то есть нет неопределенности), то то же самое можно сказать и про неопределенность Джини.



Рис. 11: Классификация новых объектов на основе обученной модели.

Доказательство. Если $H(\Omega) = 0$, то существует исход эксперимента ω_i такой, что его вероятность $P_i = 1$. Тогда вероятности всех остальных исходов (если они есть) равны 0, а значит

$$G(\Omega) = 1 - P_i^2 = 1 - 1 = 0.$$

Обратно, если $G(\Omega) = 0$, то

$$\sum_{i=1}^n P_i(1 - P_i) = 0.$$

Так как все слагаемые неотрицательны, то каждое из них равно 0, а значит $P_i(1 - P_i) = 0$ при всех $i \in \{1, 2, \dots, n\}$. В итоге, для каждого P_i выполнено одно из двух: оно либо равно 0, либо 1. Но так как сумма всех P_i равна 1,

то лишь одно $P_i = 1$, а остальные равны нулю. Значит, и энтропия такого эксперимента равна нулю. $\square$

Аналогично энтропии, неопределенность Джини максимальна в случае, когда все исходы эксперимента Ω равновозможны, а именно справедливо следующее наблюдение.

Теорема 5.1.2 *Неопределенность Джини G максимальна в случае, когда все исходы эксперимента равновозможны, то есть, когда эксперимент описывается таблицей вида*

Ω	ω_1	ω_2	$\dots$	ω_n
P	$\frac{1}{n}$	$\frac{1}{n}$	$\dots$	$\frac{1}{n}$

В этом случае неопределенность Джини равна

$$G(\Omega) = 1 - \frac{1}{n},$$

Доказательство. Ясно, что на эксперименте, заданным таблицей

Ω	ω_1	ω_2	$\dots$	ω_n
P	$\frac{1}{n}$	$\frac{1}{n}$	$\dots$	$\frac{1}{n}$

получаем, что

$$G(\Omega) = 1 - \sum_{i=1}^n \frac{1}{n^2} = 1 - \frac{1}{n}.$$

Докажем, что это значение максимально. Так как функция $\frac{1}{x}$ выпукла вниз, то для нее справедливо неравенство Йенсена: для любых чисел $p_1, p_2, \dots, p_n > 0$ таких, что $p_1 + p_2 + \dots + p_n = 1$ и любых $x_1, x_2, \dots, x_n$ из интервала выпуклости функции справедливо:

$$f(p_1x_1 + p_2x_2 + \dots + p_nx_n) \leq p_1f(x_1) + p_2f(x_2) + \dots + p_nf(x_n)$$

или

$$f\left(\sum_{i=1}^n p_i x_i\right) \leq \sum_{i=1}^n p_i f(x_i).$$

Положим $p_i = P_i$ и $x_i = \frac{1}{P_i}$, получим

$$f\left(P_1 \cdot \frac{1}{P_1} + \dots + P_n \cdot \frac{1}{P_n}\right) = f(n) = \frac{1}{n} \leq \sum_{i=1}^n P_i \frac{1}{P_i} = \sum_{i=1}^n P_i^2,$$

откуда

$$1 - \sum_{i=1}^n P_i^2 \leq 1 - \frac{1}{n}.$$

□

Легко видеть, что, как и энтропия, неопределенность Джини растет с ростом количества равновозможных исходов эксперимента Ω .

Следствие 5.1.3 Из последней теоремы легко получить важное следствие: неопределенность Джини $G(\Omega)$ любого эксперимента Ω всегда находится в следующих пределах:

$$0 \leq G(\Omega) < 1.$$

Как и ранее, резонно задаться вопросом: а как определяется неопределенность Джини в случае эксперимента (Ω, Θ) ? Напомним, что экспериментом (Ω, Θ) называется произвольное множество пар исходов (ω_i, θ_j) , $i \in \{1, 2, \dots, m\}$, $j \in \{1, 2, \dots, n\}$, каждой из которых сопоставлено число $P_{ij} \geq 0$, называемое вероятностью исхода (ω_i, θ_j) такое, что

$$\sum_{i=1}^m \sum_{j=1}^n P_{ij} = 1.$$

При этом эксперимент (Ω, Θ) может быть описан (и отождествлен) следующей таблицей:

(Ω, Θ)	θ_1	θ_2	$\dots$	θ_n
ω_1	P_{11}	P_{12}	$\dots$	P_{1n}
ω_2	P_{21}	P_{22}	$\dots$	P_{2n}
$\dots$	$\dots$	$\dots$	$\dots$	$\dots$
ω_m	P_{m1}	P_{m2}	$\dots$	P_{mn}

А тогда, для эксперимента Ω при условии, что эксперимент Θ оказался в состоянии θ_j , где $j \in \{1, 2, \dots, n\}$ могут быть составлены следующие n таблиц условных вероятностей:

$$\begin{array}{c|c|c|c|c} (\Omega, \theta_j) & (\omega_1|\theta_j) & (\omega_2|\theta_j) & \dots & (\omega_m|\theta_j) \\ \hline P & P(\omega_1|\theta_j) & P(\omega_2|\theta_j) & \dots & P(\omega_m|\theta_j) \end{array}.$$

Понятно, что каждая из таблиц описывает эксперимент, для которого можно вычислить неопределенность Джини. Как и в случае с энтропией, введем следующее определение.

Определение 5.1.2 Условной неопределенностью Джини эксперимента Ω при условии, что эксперимент Θ оказался в состоянии θ_j , $j \in \{1, 2, \dots, n\}$ называется число

$$G(\Omega|\theta_j) = 1 - \sum_{i=1}^m P^2(\omega_i|\theta_j).$$

В результате, для каждого состояния θ_j , которое происходит с некоторой вероятностью $P(\theta_j)$, неопределенность Джини принимает значения $G(\Omega|\theta_j)$, а значит является случайной величиной с рядом распределения:

$$\begin{array}{c|c|c|c} G(\Omega|\theta_j) & G(\Omega|\theta_1) & \dots & G(\Omega|\theta_n) \\ \hline P & P(\theta_1) & \dots & P(\theta_n) \end{array}.$$

Так, полученную систему хорошо характеризует так называемая взвешенная неопределенность Джини.

Определение 5.1.3 *Взвешенной неопределенностью Джини эксперимента Ω при условии, что произошел эксперимент Θ , называется величина*

$$G(\Omega|\Theta) = E(G(\Omega|\theta_j)) = \sum_{j=1}^n P(\theta_j)G(\Omega|\theta_j).$$

Прирост информации, основывающийся на понятии неопределенности Джини, вводится следующим образом.

Определение 5.1.4 *Приростом Джини (Gini Gain) называется величина*

$$GG(\Omega|\Theta) = G(\Omega) - G(\Omega|\Theta).$$

Значение прироста Джини используют при построении деревьев принятия решений аналогично тому, как мы использовали прирост информации: каждый раз на первом шаге алгоритма выбирается наибольший прирост Джини.

5.2 Небольшое сравнение прироста Джини и энтропии

На практике рассмотренные критерии прироста информативности дают почти одинаковый результат. В этом легко убедиться, построив, для примера, графики функций энтропии и удвоенной неопределенности Джини в случае двух исходов:

$$\begin{aligned} I_{Entropy} &= -p \log_2 p - (1-p) \log_2 (1-p), \\ I_{Gini} &= 2 \cdot (p(1-p) + (1-p)(1-(1-p))). \end{aligned}$$

Удвоение неопределенности Джини позволяет нормировать значения функции I_{Gini} до единицы, что, условно, «уравнивает единицы измерения». Как видно рисунка [12](#), неопределенность системы с двумя исходами для различных значений вероятности сопоставимы.

Таким образом, нет явных предпосылок использовать конкретный метод измерения информативности, так как они оба справляются со своей задачей и дают почти одинаковый результат. Однако вычисление энтропии – задача более затратная (с точки зрения вычислений) из-за присутствующего в определении логарифма. Именно по этой причине часто, по умолчанию, в инструментах используется неопределенность Джини.

Рис. 12: Сравнение энтропии и неопределенности Джини.

5.3 Прирост Джини на данных

Вернемся к примеру с кошками. Перед вами таблица, содержащая информацию о породе, цвете шерсти и росте в холке, которые влияют на привлекательность конкретной кошки, участвующей в соревнованиях.

Порода	Шерсть	Рост	Привлекательность
Британец	Белый	Высокий	Нет
Британец	Серый	Высокий	Да
Британец	Белый	Низкий	Да
Мейн-кун	Белый	Высокий	Нет
Мейн-кун	Коричневый	Высокий	Да
Мейн-кун	Коричневый	Низкий	Нет
Рэгдолл	Серый	Высокий	Да
Мейн-кун	Серый	Низкий	Да

Условные вероятности отнесения к целевому классу «Привлекательность» в зависимости от породы были найдены ранее, они равны:

$$P(\text{Привлекательность} = \text{Да} | \text{Порода} = \text{Британец}) = \frac{2}{3},$$

$$P(\text{Привлекательность} = \text{Нет} | \text{Порода} = \text{Британец}) = \frac{1}{3},$$

$$P(\text{Привлекательность} = \text{Да} | \text{Порода} = \text{Мейн-кун}) = \frac{1}{2},$$

$$P(\text{Привлекательность} = \text{Нет} | \text{Порода} = \text{Мейн-кун}) = \frac{1}{2},$$

$$P(\text{Привлекательность} = \text{Да} | \text{Порода} = \text{Рэгдолл}) = 1$$

$$P(\text{Привлекательность} = \text{Нет} | \text{Порода} = \text{Рэгдолл}) = 0.$$

Тогда неопределенность Джини для каждой породы будет принимать следующие значения:

$$G(\text{Привлекательность} | \text{Порода} = \text{Британец}) = 1 - \left(\left(\frac{2}{3} \right)^2 + \left(\frac{1}{3} \right)^2 \right) = \frac{4}{9},$$

$$G(\text{Привлекательность} | \text{Порода} = \text{Мейн-кун}) = 1 - \left(\left(\frac{1}{2} \right)^2 + \left(\frac{1}{2} \right)^2 \right) = \frac{1}{2},$$

$$G(\text{Привлекательность}|\text{Порода} = \text{Рэгдолл}) = 1 - (1^2 + 0^2) = 0.$$

При этом состояния, то есть выбор конкретной породы, определяются с некоторой вероятностью, а именно: $\frac{3}{8}$, $\frac{4}{8}$ и $\frac{1}{8}$ соответственно. Запишем полученные значения в таблицу:

$G(\text{Привлекательность} \text{Порода})$	$\frac{4}{9}$	$\frac{1}{2}$	0
P	$\frac{3}{8}$	$\frac{4}{8}$	$\frac{1}{8}$

Окончательно, взвешенная неопределённость Джини составит:

$$G(\text{Привлекательность}|\text{Порода}) = \frac{3}{8} \cdot \frac{4}{9} + \frac{4}{8} \cdot \frac{1}{2} + \frac{1}{8} \cdot 0 = \frac{5}{12}.$$

При этом неопределённость Джини, эксперимента «Привлекательность» равна:

$$G(\text{Привлекательность}) = 1 - \left(\left(\frac{5}{8} \right)^2 + \left(\frac{3}{8} \right)^2 \right) = \frac{15}{32},$$

а значит прирост Джини:

$$GG(\text{Привлекательность}|\text{Порода}) = \frac{15}{32} - \frac{5}{12} = \frac{5}{96} \approx 0.052.$$

Аналогичным образом рассчитываются прирост Джини для всех атрибутов. Конечно, атрибут – шерсть, в такой эвристике тоже лучше всего характеризует прирост информации, как и в случае с энтропией.

